ITBA

(20262Q) DIA.04
Introducción a la Ingeniería de Datos
Comisión A

¿Alcanza un dataset público de radiografías lumbares para entrenar el detector de vértebras de un CDSS de inestabilidad espinal?

Proyecto Final — Defensa académica

Marcos Kantor
Director: Ramiro M. Irastorza (IFLySiB-CONICET)
Codirector: Marcelo A. Cappelletti (LEICI-CONICET, UNAJ)

Recorrido de la exposición

1. Pregunta de investigación y dataset
2. **Demostración del tablero**
3. Proceso de ETL
4. Datos faltantes y anomalías
5. Modelo entidad-relación transaccional
6. Diseño del almacén de datos
7. Resultados y veredicto

Artefactos (repositorio GitHub del curso)

`Proyecto_final.ipynb` — Colab reproducible
`spine_oltp.db` — SQLite transaccional
`spine_dw.db` — SQLite almacén
`app.py` — tablero Streamlit
`data/raw/…zip` — dato crudo (CC BY 4.0)

Se ejecuta con *Entorno de ejecución → Ejecutar todo*, sin credenciales ni archivos subidos a mano.

La pregunta

El **SINS** (*Spinal Instability Neoplastic Score*) se evalúa **vértebra por vértebra**: localización, alineación, colapso, compromiso posterior.

La primera etapa de un CDSS que lo asista es **encontrar y delimitar cada vértebra**.

Pregunta de investigación

¿El dataset público *Lumbar Spine* tiene la cobertura, el balance, la calidad geométrica y la coherencia anatómica necesarias para entrenar el detector L1–L5?

	Preguntas de análisis (guían el almacén y el tablero)
P1	**Cobertura y balance:** ¿cuántas imágenes tienen L1–L5 completas? ¿están balanceadas las clases?
P2	**Calidad geométrica:** ¿qué anotaciones tienen tamaño o forma atípicos para su vértebra?
P3	**Coherencia anatómica:** ¿se respeta el orden L1→L5 y el aumento de tamaño hacia caudal?
P4	**Representatividad:** ¿qué diagnósticos, sexos y edades cubre?

El dataset crudo

Lumbar Spine — rp-team, Roboflow Universe, versión 1, licencia CC BY 4.0



50 radiografías

34 anotadas

170 polígonos

5 clases L1–L5

- Polígonos: cada línea es `clase x1 y1 … xn yn` en $[0, 1]$.
- De **144**×**725** a **1669**×**3246** px: recortes lumbares y columnas completas.
- El **nombre de archivo codifica datos clínicos**:
  `N18-Olisthesis-L4-5-F-56-Yrs_jpg.rf.<hash>.jpg`
  diagnóstico · sexo · edad ⇒ expresiones regulares (P4).
- La espondilolistesis es pertinente para el criterio de **alineación** del SINS.

Demostración del tablero

Tablero interactivo (Streamlit)

Lee sólo del almacén `spine_dw.db` — en Colab se abre al final del notebook

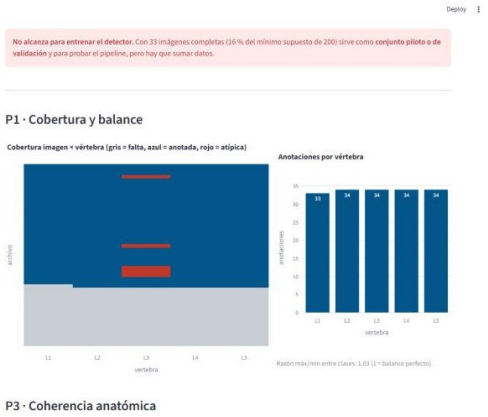


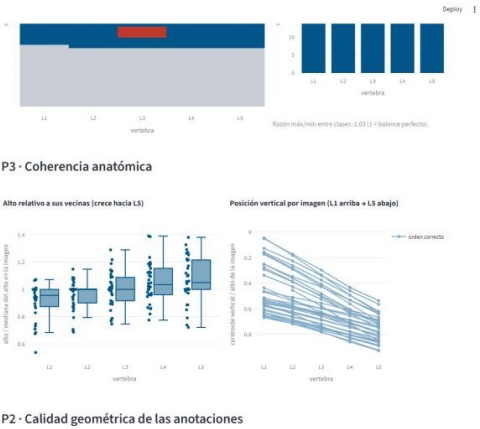
Mensaje explícito: un **veredicto** sobre la aptitud del dataset.

- El umbral de imágenes completas es un **supuesto**: se ajusta en la barra lateral y el veredicto cambia en vivo.
- Filtros por diagnóstico y sexo.
- Interruptor para excluir anotaciones atípicas.

En vivo: P1 → P3 → P2 → P4.

Tablero: cobertura y anatomía



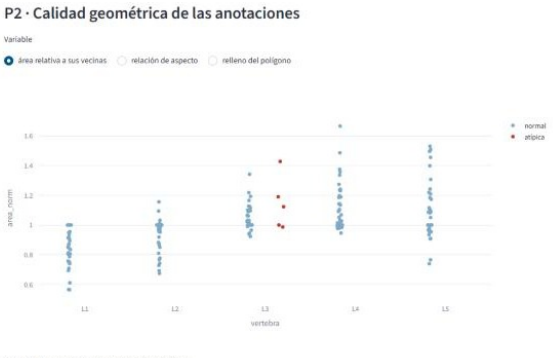


P1 Grilla imagen × vértebra: gris = falta, rojo = atípica. Las filas grises son las 16 imágenes sin anotar.

P3 El tamaño relativo crece hacia L5 y cada imagen respeta el orden vertical L1→L5.

Tablero: calidad geométrica



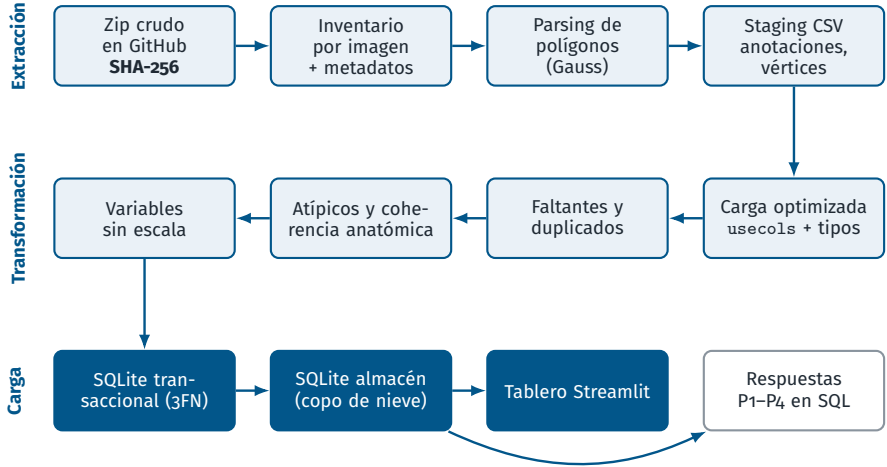


P2 La variable se elige en vivo: área relativa a sus vecinas, relación de aspecto o relleno del polígono.

En rojo, las anotaciones marcadas; debajo, la tabla con el **motivo** de cada una para la revisión manual.

Proceso de ETL

Pipeline


Extracción
Zip crudo en GitHub **SHA-256**
Inventario por imagen + metadatos
Parsing de polígonos (Gauss)
Staging CSV anotaciones, vértices
Transformación
Carga optimizada `usecols` + tipos
Faltantes y duplicados
Atípicos y coherencia anatómica
Variables sin escala
Carga
SQLite transaccional (3FN)
SQLite almacén (copo de nieve)
Tablero Streamlit
Respuestas P1–P4 en SQL

Extracción reproducible y carga optimizada

Extracción sin credenciales

- Roboflow exige cuenta y API key ⇒ no es *estrictamente reproducible*.
- La licencia **CC BY 4.0** permite redistribuir: el zip crudo se publicó **sin modificar** en `data/raw/`.
- Descarga por URL pública + verificación **SHA-256**: todos obtienen los mismos bytes.
- Proceso **idempotente**: si el archivo está y el hash coincide, no se vuelve a bajar.
- El SDK de Roboflow queda como alternativa opcional.

Elección de columnas y tipado

Variable	Tipo
`clase_id`, `linea`	`int8`
`ancho_px`, `n_vertices`	`int16`
`edad` (puede faltar)	`Int8` *nullable*
coordenadas, áreas	`float32`
`archivo`, `split`, `sexo`	`category`

Tabla de staging	Filas	Ahorro
imágenes	50	47 %
anotaciones	170	68 %
vértices	681	85 %

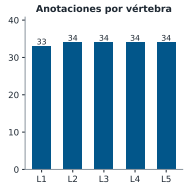
Ojo: `ancho*alto` en `int16` se desborda ⇒ `float` antes de multiplicar.

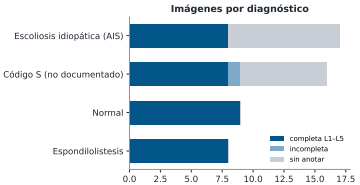
Datos faltantes y anomalías

Valores faltantes: tres niveles

Nivel	Qué falta	Decisión
Imagen	16 de 50 sin anotaciones	**se conservan** con `anotada = 0`
Vértebra	imagen anotada sin alguna de L1–L5	se mide la **completitud**
Atributo	coordenadas o clase inválidas (0 casos)	**descarte**
Metadato	sexo no identificable (1 imagen)	**nulo**, sin imputar

No se imputa geometría: una vértebra inventada contamina el entrenamiento. **No se imputan datos clínicos:** inventaría pacientes y sesgaría P4.





Hallazgo

Las 16 imágenes sin anotar son **todas** de escoliosis (9) o del código «S» (7): el faltante **no es aleatorio** (MNAR). Descartarlas sin registrarlo ocultaría un sesgo de cobertura.

Duplicados e inválidos geométricos

Duplicados

El grano esperado es **una anotación por (imagen, vértebra)**. En `N20-S-79-F` la **L2 aparece dos veces**.

Regla: se conserva la que está más cerca de la posición vertical mediana de L2 en todo el dataset.

Línea	c_y/alto	dist. a mediana	
3	0,455	0,118	**se conserva**
4	0,345	0,229	descarte

Resultado: 170 $\rightarrow$ **169** anotaciones; la imagen queda incompleta (4 vértebras).

Reglas de dominio

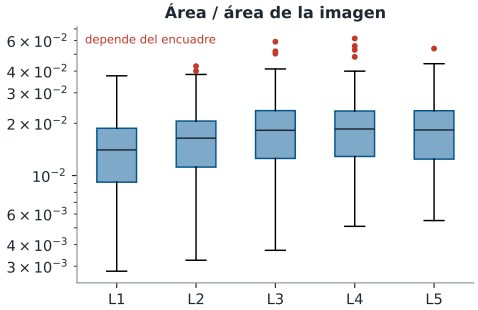
- Polígono fuera de la imagen más de un 2 % $\Rightarrow$ **descarte**.
- Desborde menor (redondeo del anotador) $\Rightarrow$ **recorte** al borde.
- Área < 1 px^2 o menos de 3 vértices $\Rightarrow$ **descarte**.

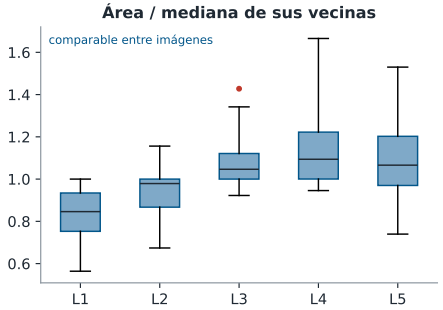
Resultado: **0 casos**; quedan como control para futuras versiones.

Criterio: se descarta sólo lo imposible; lo raro se marca.

Atípicos (1): elegir bien la variable

El área en píxeles o relativa a la imagen depende del encuadre





Primer intento: área / área de la imagen.
Marcó **49 de 169** anotaciones: *imágenes enteras*, porque una es un recorte lumbar y otra una columna completa.

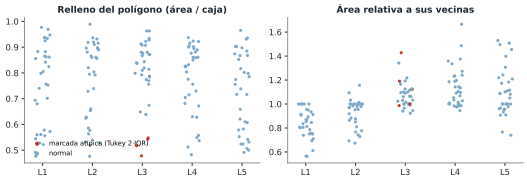
Decisión: normalizar **dentro de cada imagen**: `area_norm` = área / mediana del área de sus vecinas.
Atípicos: **5 de 169** — una vértebra es rara si no se parece a sus vecinas.

Atípicos (2): criterio estadístico

Variables por vértebra: `area_norm`, `aspecto` (ancho/alto), `relleno` (área del polígono / área de la caja).

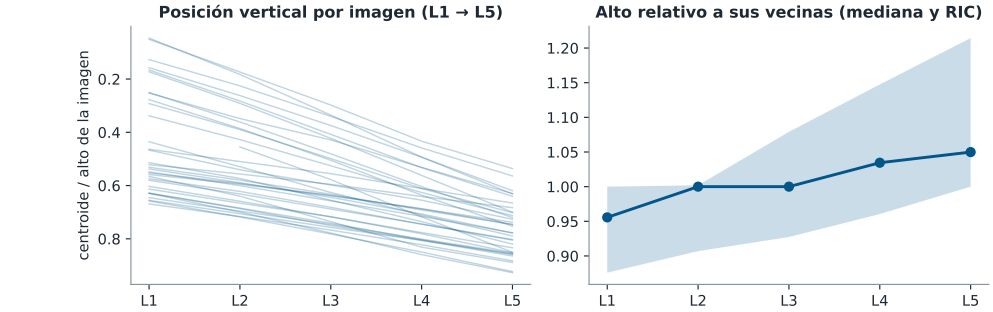
1. **Shapiro–Wilk** por vértebra (n ≈ 34): **10 de 15** combinaciones **no** son normales (α = 0,05).
2. $\Rightarrow$ el corte $|z| > 3$ no tiene sustento: se usan **Tukey fences** $Q_3 + 2 \cdot \mathrm{RIC}$.
3. **Mahalanobis robusta** (mediana y MAD) sobre las 3 variables: límite $\chi^2_{0{,}999}(3) = 16{,}27$; detecta combinaciones raras.

Decisión: se **marcan** con su motivo; no se descartan.



Los 5 marcados son L3: 4 por **relleno bajo** (contorno poco ajustado al cuerpo vertebral) y 1 por **área alta** respecto de sus vecinas. Van a **revisión manual**.

Coherencia anatómica: una validación de dominio

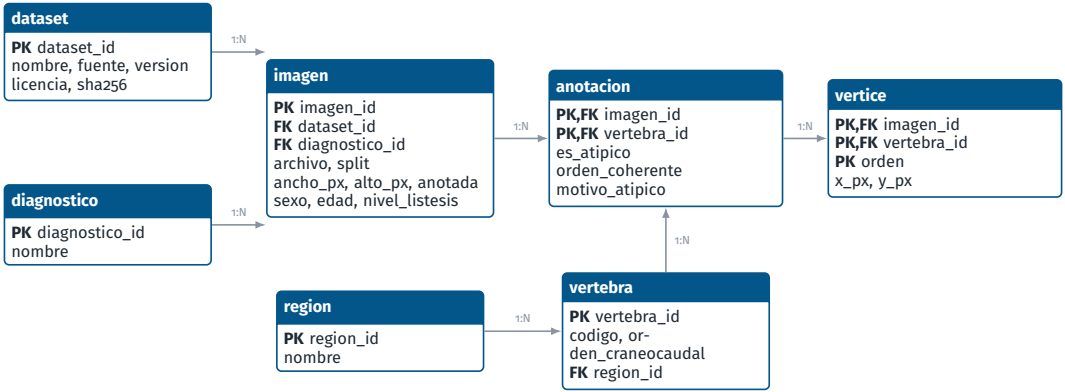


Orden craneocaudal: el centroide vertical debe crecer de L1 a L5. Detecta **etiquetas intercambiadas** entre vecinas, algo que ningún método estadístico genérico ve. Resultado: **0 violaciones**.

Progresión de tamaño: el alto relativo crece de 0,96 (L1) a 1,05 (L5), coherente con el aumento del cuerpo vertebral hacia caudal: las anotaciones son **anatómicamente plausibles**.

Base de datos transaccional

Modelo entidad-relación (SQLite)



Una sola clave por tabla. `anotacion` y `vertice` usan **claves compuestas** formadas por las tablas que conectan.

Por qué está normalizado

1FN — atomicidad

El polígono es una lista de largo variable (**grupo repetitivo**). Guardarlo como texto violaría la atomicidad: cada vértice es una fila de `vertice`.

2FN — sin dependencias parciales

Con clave (`imagen_id`, `vertebra_id`), la resolución o el sexo dependen sólo de la imagen y viven en `imagen`; el código y el orden, sólo de la vértebra. En `anotacion` quedan las marcas de calidad, que dependen del par.

3FN — sin transitivas

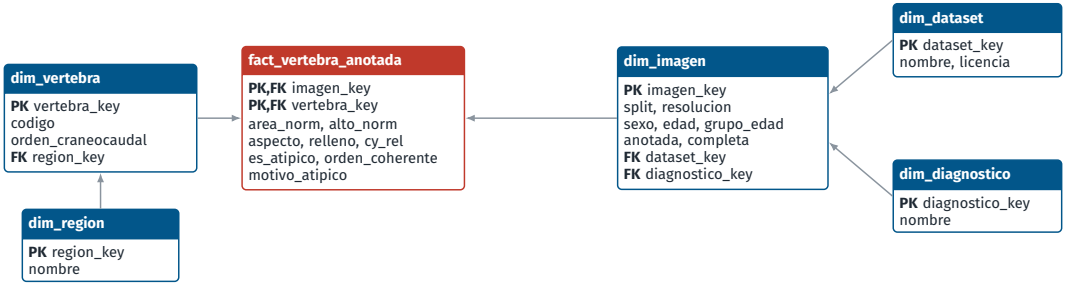
La región depende de la vértebra (`region`); el nombre del diagnóstico, de su id (`diagnostico`); la licencia y el hash, del dataset.

- **No se guardan derivados** (caja, área): se calculan desde los vértices al cargar el almacén.
- Claves foráneas activas y `foreign_key_check`: **0 violaciones**; `CHECK` sobre `split`, `sexo`, `edad`.

Almacén de datos

Copo de nieve

Grano: una vértebra anotada en una imagen



- **PK de hechos compuesta** por las claves de sus dimensiones.
- **Copo de nieve:** región → vértebra, dataset → imagen, diagnóstico → imagen.

- Sumar columna cervical o torácica = **agregar filas**; los hechos no cambian.
- Miembro **«sin dato»** en `dim_diagnostico`; se carga **desde la base transaccional**.

Cada métrica responde a una pregunta

Métrica / atributo	Cálculo en el ETL	Responde
`COUNT(*)` sobre hechos	cantidad de anotaciones	**P1**
`dim_imagen.completa`	1 si la imagen tiene las 5 vértebras	**P1**
`area_norm`	área del polígono / mediana del área de las vértebras de la misma imagen	**P2, P3**
`aspecto`, `relleno`	ancho/alto de la caja; área del polígono / área de la caja	**P2**
`es_atipico`, `motivo_atipico`	marca de calidad (Tukey, Mahalanobis, orden)	**P2**
`alto_norm`, `cy_rel`	alto relativo a sus vecinas; centroide vertical / alto de la imagen	**P3**
`orden_coherente`	1 si respeta el orden L1→L5	**P3**
diagnóstico, sexo, `grupo_edad`	extraídos del nombre de archivo	**P4**

No hay métricas que ninguna pregunta use.

Resultados

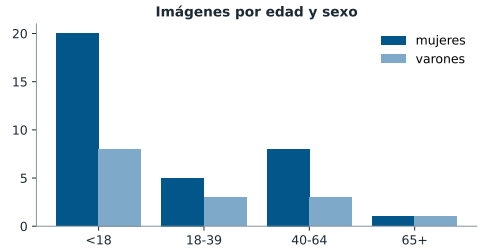
33
imágenes completas L1–L5

1,03
razón máx/mín entre clases

5
anotaciones atípicas (3 %)

0
violaciones del orden L1→L5

- **P1:** clases balanceadas, pero un tercio de las imágenes sin anotar.
- **P2:** calidad alta; 5 contornos a revisar.
- **P3:** orden y tamaño coherentes con la anatomía.
- **P4:** escoliosis 17, «S» 16, normales 9, listesis 8; mayoría mujeres y menores de 18.



Veredicto

Respuesta a la pregunta de investigación

El dataset tiene anotaciones **de buena calidad** y **anatómicamente coherentes**, pero con **33 imágenes completas** no alcanza para entrenar el detector del CDSS: es el 16 % del mínimo supuesto (200).

Uso recomendado en la tesis:

- conjunto **piloto o de validación**;
- banco de pruebas del pipeline de datos;
- integrar otros datasets: el copo de nieve lo admite sin rediseño.

Limitaciones

- El código «S» no está documentado por la fuente.
- Los metadatos dependen de la convención del nombre de archivo.
- Imagen $\neq$ paciente: no hay identificador de paciente.
- Umbral de 200 imágenes: supuesto explícito y ajustable.

Uso de inteligencia artificial

Declaración

- «Claude Sonnet 4.5» para «redacción de celdas Markdown de la primera versión».
- «ChatGPT 4.5» para «sugerir esquemas SQLite de la primera versión».
- «GitHub Copilot» para «autocompletar parsing YOLO y gráficos».
- «Claude Opus 5.5» para «reestructurar el notebook: extracción sin credenciales, control de calidad, modelos con claves compuestas y tablero».

Human-in-the-loop: decisiones verificadas

- Hash del zip y *Ejecutar todo* en una sesión nueva.
- Superposición de polígonos sobre la radiografía.
- Revisión manual del duplicado y de la tabla nombre $\rightarrow$ metadatos.
- Rechazo del área relativa a la imagen (49 falsos atípicos) y cambio a normalización por vecinas.
- Detección del desbordamiento `int16`.
- Cada métrica contrastada con P1–P4.

¡Gracias!

Preguntas

`github.com/marcoskantor/Curso_Introduccion_Ingenieria_Datos`

Proyecto_final.ipynb · app.py · data/raw/

Anexo para el coloquio

A1 · Parsing y área del polígono

```
x = vals[0::2] * ancho_px # desnormalizar
y = vals[1::2] * alto_px
area = 0.5 * abs(np.dot(x, np.roll(y, -1))
               - np.dot(y, np.roll(x, -1)))
```

Fórmula de Gauss (*shoelace*):

$$A = \frac{1}{2}\left|\sum_{i=1}^{n}(x_i\,y_{i+1} - y_i\,x_{i+1})\right|$$

con $x_{n+1} = x_1$; `np.roll` implementa el índice cíclico.

- 4 valores ⇒ caja `xc yc w h`: se convierte a sus 4 esquinas.
- Número impar o < 6 valores ⇒ se **rechaza** la línea y se registra.
- Caja envolvente = mín/máx de los vértices; centroide = media de los vértices.
- `relleno` = área del polígono / área de la caja: 1 si el contorno es un rectángulo.

A2 · Tukey y Mahalanobis robusta

```
q1, q3 = g[var].quantile([0.25, 0.75])
lo = q1 - 2.0 * (q3 - q1)
hi = q3 + 2.0 * (q3 - q1)

rel = np.log(X / X.groupby(vertebra).median())
z = (rel - rel.median()) / MAD(rel)
d2 = z @ inv(cov(z)) @ z.T # por fila
atipico = d2 > chi2.ppf(0.999, 3) # 16.27
```

- **¿Por qué Tukey y no *z*?** Shapiro–Wilk rechaza normalidad en 10 de 15 casos: $\pm 3\sigma$ supone normalidad; los cuartiles no.
- **¿Por qué $k = 2$?** Más conservador que 1,5: con $n \approx 34$ por vértebra se evita marcar variación anatómica normal.
- **¿Por qué robusta?** Media y desvío se contaminan con los propios atípicos; mediana y MAD no.
- **¿Por qué logaritmo?** Las razones son asimétricas (0,5 y 2 están a la misma distancia de 1).

A3 · Orden craneocaudal y regla de duplicados

```
# duplicados: el mas cercano a la posicion
    esperada
anot["dist"] = (anot.cy_rel
   - anot.vertebra.map(mediana_cy)).abs()
anot = (anot.sort_values("dist")
      .drop_duplicates(["archivo", "vertebra"])
           )

# orden: cy debe crecer de L1 a L5
prev = anot.groupby("archivo").cy_rel.shift(1)
nxt = anot.groupby("archivo").cy_rel.shift(-1)
roto = (prev.notna() & (anot.cy_rel <= prev)) |
     \
     (nxt.notna() & (anot.cy_rel >= nxt))
```

- La posición vertical se normaliza por el alto de la imagen (c_y/alto) para comparar imágenes.
- La mediana por vértebra es el «lugar esperado» de esa vértebra.
- El control de orden compara cada vértebra con sus vecinas en la misma imagen (`shift` dentro del grupo).
- Supuesto: radiografías con la columna vertical (se verificó visualmente).

A4 · Carga del almacén desde la base transaccional

```
ATTACH DATABASE 'spine_oltp.db' AS oltp;
INSERT INTO dim_imagen
SELECT i.imagen_id, i.archivo, i.split, ...,
       COALESCE(i.sexo, 'sin dato'),
       CASE WHEN i.edad < 18 THEN '<18' ... END,
       COUNT(a.vertebra_id),
       CASE WHEN COUNT(a.vertebra_id) = 5
            THEN 1 ELSE 0 END, -- completa
       COALESCE(i.diagnostico_id, 0) -- miembro "
            sin dato"
FROM oltp.imagen i
LEFT JOIN oltp.anotacion a USING (imagen_id)
GROUP BY i.imagen_id;
```

- `LEFT JOIN`: las imágenes sin anotar también entran a la dimensión (P1 las necesita).
- Hechos: métricas recalculadas desde `vertice`, la fuente de verdad.
- `area_norm` y `alto_norm` se calculan con la mediana **por imagen** (`groupby + transform`).
- Validación: conteos por tabla y `PRAGMA foreign_key_check`.