ITBA

(20262Q) DIA.04
Introducción a la Ingeniería de Datos
Comisión A

¿Alcanzan los datos públicos de radiografías lumbares para entrenar el detector de vértebras de un CDSS de inestabilidad espinal?

Proyecto Final — Defensa académica

Marcos Kantor
Director: Ramiro M. Irastorza (IFLySiB-CONICET)
Codirector: Marcelo A. Cappelletti (LEICI-CONICET, UNAJ)

La respuesta, antes que la evidencia

Idea principal de la exposición

En una oración

Los datos públicos **alcanzan** para entrenar el detector de vértebras L1–L5 **sólo si se combinan dos fuentes**: NHANES aporta el volumen y Lumbar Spine la forma, la clínica y las vistas de frente. Antes hay que **enderezar el 11 %** de NHANES.

33
completas en Lumbar Spine: no alcanza

4.405
completas en NHANES

477
radiografías giradas o invertidas

36°
de Cobb en escoliosis (7° en normales)

Lo que sigue es la evidencia: extracción, calidad, modelado y tablero.

Recorrido de la exposición

1. Pregunta de investigación y dataset
2. **Demostración del tablero**
3. Proceso de ETL
4. Datos faltantes y anomalías
5. **Descriptores de forma con OpenCV** y análisis exploratorio
6. Modelo entidad-relación transaccional
7. Diseño del almacén de datos
8. Resultados y veredicto

Artefactos (repositorio GitHub del curso)

`Proyecto_final.ipynb` — Colab reproducible
`spine_oltp.db` — SQLite transaccional
`spine_dw.db` — SQLite almacén
`app.py` — tablero Streamlit
`data/raw/…zip` — dato crudo (CC BY 4.0)

Se ejecuta con *Entorno de ejecución → Ejecutar todo*, sin credenciales ni archivos subidos a mano.

La pregunta

El **SINS** (*Spinal Instability Neoplastic Score*) se evalúa **vértebra por vértebra**: localización, alineación, colapso, compromiso posterior.

La primera etapa de un CDSS que lo asista es **encontrar y delimitar cada vértebra**.

Pregunta de investigación

¿El dataset público *Lumbar Spine* tiene la cobertura, el balance, la calidad geométrica y la coherencia anatómica necesarias para entrenar el detector L1–L5?

	Preguntas de análisis (guían el almacén y el tablero)
P1	**Cobertura y balance:** ¿cuántas imágenes tienen L1–L5 completas? ¿están balanceadas las clases? ¿Y sumando una segunda fuente?
P2	**Calidad geométrica:** ¿qué anotaciones tienen tamaño o forma atípicos para su vértebra?
P3	**Coherencia anatómica:** ¿se respeta el orden L1→L5 y el aumento de tamaño hacia caudal?
P4	**Representatividad:** ¿qué diagnósticos, sexos y edades cubre?
P5	**Alineación:** ¿la inclinación y el desplazamiento medidos con momentos de imagen distinguen las patologías?

Lumbar Spine: pocos datos, con contornos y clínica

rp-team, Roboflow Universe, versión 1, licencia CC BY 4.0



50 radiografías

34 anotadas

170 polígonos

5 clases L1–L5

- Polígonos: cada línea es `clase x1 y1 … xn yn` en $[0, 1]$.
- De **144**×**725** a **1669**×**3246** px: recortes lumbares y columnas completas.
- El **nombre de archivo codifica datos clínicos**:

  `N18-Olisthesis-L4-5-F-56-Yrs_jpg.rf.<hash>.jpg`

  diagnóstico · sexo · edad ⇒ expresiones regulares (P4).
- La espondilolistesis es pertinente para el criterio de **alineación** del SINS.

NHANES multiplica el volumen, pero con cajas y de perfil

Segunda fuente para responder P1, P3 y el veredicto

4.436 radiografías de perfil

22.185 cajas L1–L5

- Radiografías lumbares de la encuesta nacional de salud **NHANES** (EE. UU.), anotadas en Roboflow Universe (`main-kybbe`), **CC BY 4.0**.
- Anotadas con **cajas**, no polígonos, y estiradas a 640×640 por la fuente.
- Se publica en GitHub **sólo la anotación COCO** (542 KB): P1 necesita qué vértebras hay, no los píxeles.

Qué responde y qué no

Sí: P1 (cobertura y veredicto) y P3 (orden y orientación).

No: P2 y P5. Una caja alineada con los ejes no tiene forma ni inclinación; P4 tampoco, porque no trae metadatos clínicos.

Se integra al mismo modelo: nueva fila en `dataset`, `imagen.dataset_id` y `anotacion.geometria = caja`.

Demostración del tablero

El tablero responde primero: con dos fuentes, alcanza

Streamlit · lee sólo del almacén `spine_dw.db` · en Colab se abre al final del notebook



Cómo leerlo

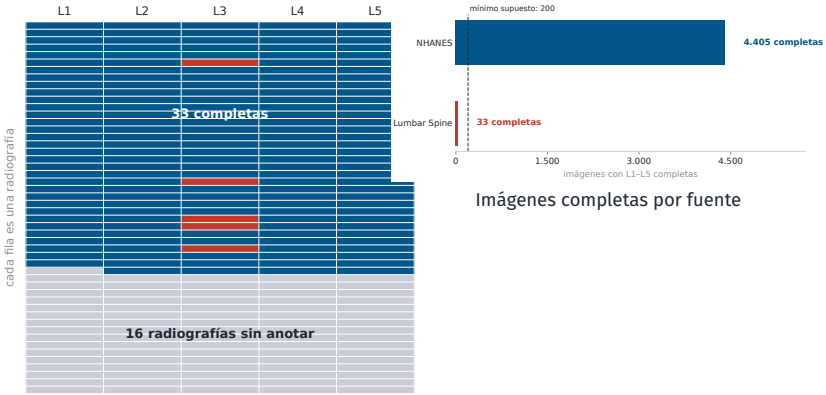
Arriba, la pregunta. Debajo, cinco indicadores, un **veredicto en color** (rojo = no alcanza, amarillo = ajuste fino, verde = apto) y la tabla por fuente.

Qué nos dice

Con las dos fuentes hay **4.438 imágenes completas**: apto. Si se deja sólo Lumbar Spine (filtro «Fuente»), vuelve el rojo: 33 no alcanzan. El mínimo (200) es un supuesto ajustable.

P1 · Lumbar Spine sola no alcanza: 33 imágenes completas

Tablero · ¿cuántas imágenes tienen L1–L5 completas?



Imágenes completas por fuente

Cómo leerlo

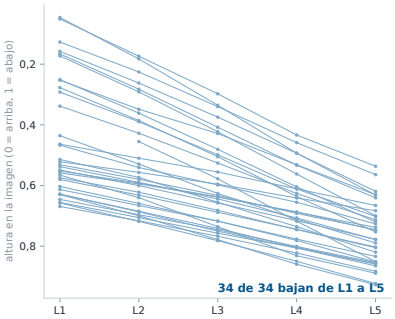
Izquierda (Lumbar Spine): **cada fila es una radiografía**; azul = anotada, rojo = atípica, gris = falta. Derecha: completas por fuente y el mínimo.

Qué nos dice

Lumbar Spine: 33 completas y **16 sin anotar**. NHANES: **4.405**. Sumadas superan el mínimo.

P3 · La anatomía se respeta; el problema es la orientación

Tablero · ¿las anotaciones respetan el orden L1→L5?



Posición de cada vértebra en su radiografía



Orientación de las radiografías

Cómo leerlo

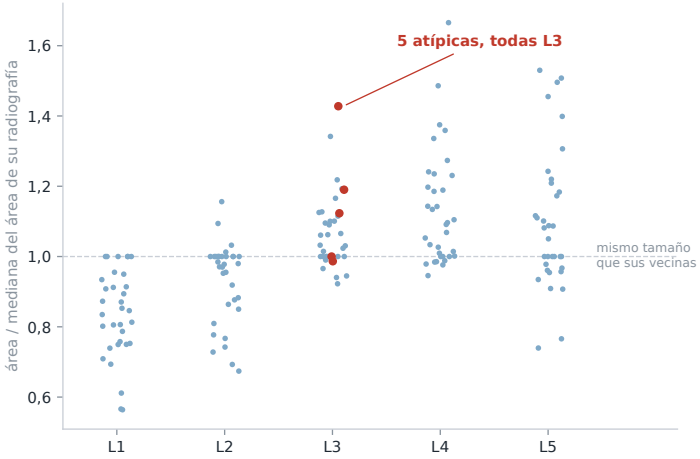
Izquierda (Lumbar Spine): **cada línea es una radiografía**; debe bajar de L1 a L5. Derecha (NHANES): en rojo, las que hay que enderezar.

Qué nos dice

Lumbar Spine: 0 errores. NHANES: **477 giradas o invertidas** (11 %) y sólo 26 cajas mal etiquetadas.

P2 · Sólo 5 de 169 contornos son atípicos

Tablero · ¿hay anotaciones mal dibujadas?



Cómo leerlo

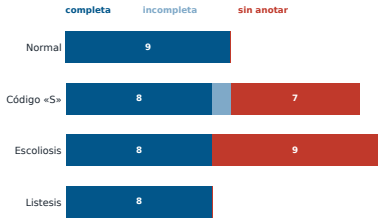
Cada punto es una vértebra anotada. 1 = mismo tamaño que las otras vértebras de su radiografía. En rojo, las que el control estadístico marcó como atípicas.

Qué nos dice

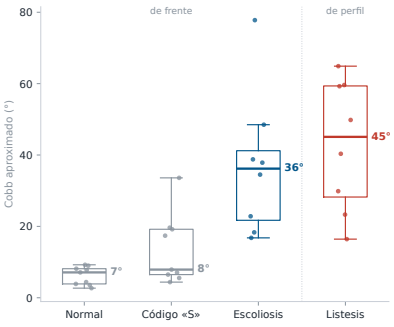
Sólo **5 de 169**, todas L3. No se borran: el tablero las lista con su motivo para **revisarlas a mano**.

P4 y P5 · Faltan escoliosis, pero el contorno mide la curva

Tablero · ¿qué cubre el dataset y qué se puede medir?



P4 · Imágenes por diagnóstico



P5 · Cobb aproximado por radiografía

Cómo leerlo

Izquierda: azul = completa, rojo = sin anotar. Derecha: **cada punto es una radiografía**; cuanto más alto, más inclinadas entre sí están sus vértebras.

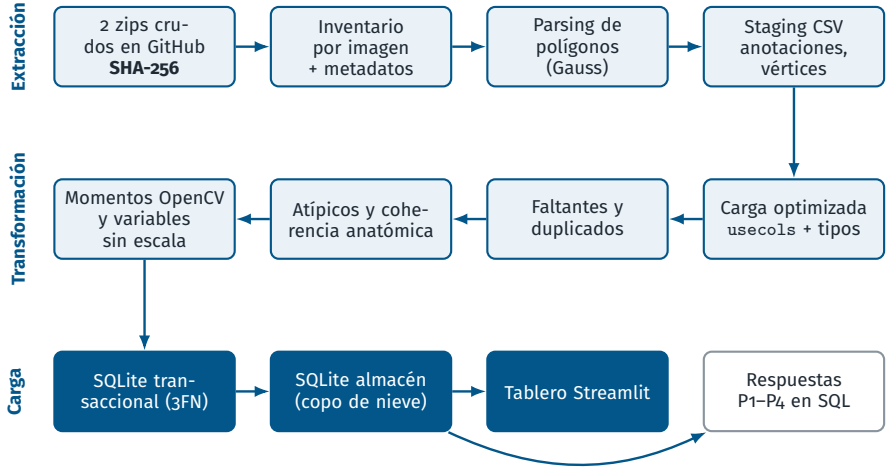
Qué nos dice

Las sin anotar son escoliosis y «S». Escoliosis: **36°**; normales: **7°**. La curva se mide desde el contorno.

Proceso de ETL

De dos zips públicos a un tablero, sin credenciales

Pipeline de extracción, transformación y carga



Extracción verificada; carga con 85 % menos memoria

Extracción sin credenciales

- Roboflow exige cuenta y API key ⇒ no es *estrictamente reproducible*.
- La licencia **CC BY 4.0** permite redistribuir: el zip crudo se publicó **sin modificar** en `data/raw/`.
- Descarga por URL pública + verificación **SHA-256**: todos obtienen los mismos bytes.
- Proceso **idempotente**: si el archivo está y el hash coincide, no se vuelve a bajar.
- El SDK de Roboflow queda como alternativa opcional.

Elección de columnas y tipado

Variable	Tipo
`clase_id`, `linea`	`int8`
`ancho_px`, `n_vertices`	`int16`
`edad` (puede faltar)	`Int8` *nullable*
coordenadas, áreas	`float32`
`archivo`, `split`, `sexo`	`category`

Tabla de staging	Filas	Ahorro
imágenes	50	53 %
anotaciones	170	68 %
vértices	681	85 %

Ojo: `ancho*alto` en `int16` se desborda ⇒ `float` antes de multiplicar.

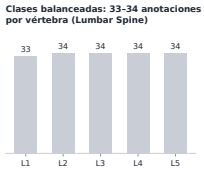
Datos faltantes y anomalías

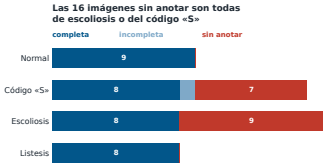
Faltantes no aleatorios: 16 sin anotar, todas AIS o «S»

Valores faltantes en cuatro niveles

Nivel	Qué falta	Decisión
Imagen	16 de 50 sin anotaciones	**se conservan** con `anotada = 0`
Vértebra	imagen anotada sin alguna de L1–L5	se mide la **completitud**
Atributo	coordenadas o clase inválidas (0 casos)	**descarte**
Metadato	sexo no identificable (1 imagen)	**nulo**, sin imputar

No se imputa geometría: una vértebra inventada contamina el entrenamiento. **No se imputan datos clínicos:** inventaría pacientes y sesgaría P4.





Hallazgo

Las 16 imágenes sin anotar son **todas** de escoliosis (9) o del código «S» (7): el faltante **no es aleatorio** (MNAR). Descartarlas sin registrarlo ocultaría un sesgo de cobertura.

Se descarta sólo lo imposible: 1 duplicado y 0 inválidos

Duplicados e inválidos geométricos

Duplicados

El grano esperado es **una anotación por (imagen, vértebra)**. En `N20-S-79-F` la **L2 aparece dos veces**.

Regla: se conserva la que está más cerca de la posición vertical mediana de L2 en todo el dataset.

Línea	c_y/alto	dist. a mediana	
3	0,455	0,118	**se conserva**
4	0,345	0,229	descarte

Resultado: 170 → **169** anotaciones; la imagen queda incompleta (4 vértebras).

Reglas de dominio

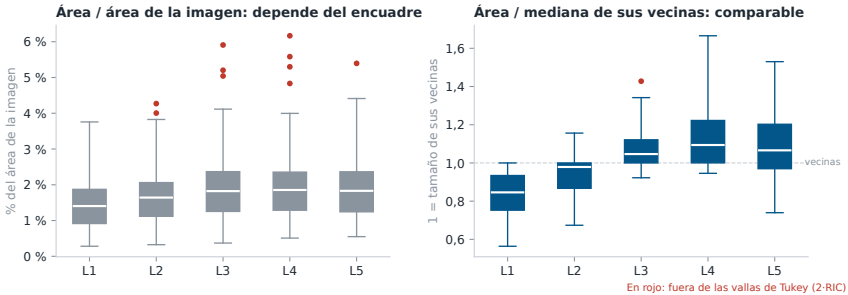
- Polígono fuera de la imagen más de un 2 % ⇒ **descarte**.
- Desborde menor (redondeo del anotador) ⇒ **recorte** al borde.
- Área < 1 px^2 o menos de 3 vértices ⇒ **descarte**.

Resultado: **0 casos**; quedan como control para futuras versiones.

Criterio: se descarta sólo lo imposible; lo raro se marca.

Atípicos (1): la variable equivocada inventa 49 atípicos

El área relativa a la imagen depende del encuadre; la relativa a sus vecinas, no



Primer intento: área / área de la imagen. Marcó **49 de 169** anotaciones: *imágenes enteras*, porque una es un recorte lumbar y otra una columna completa.

Decisión: normalizar **dentro de cada imagen**: `area_norm` = área / mediana del área de sus vecinas.
Atípicos: **5 de 169** — una vértebra es rara si no se parece a sus vecinas.

Atípicos (2): sin normalidad, Tukey y Mahalanobis robusta

Variables por vértebra: `area_norm`, `aspecto` (ancho/alto), `relleno` (área del polígono / área de la caja).

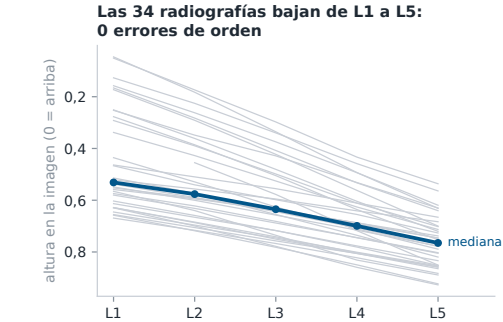
1. **Shapiro–Wilk** por vértebra (n ≈ 34): **10 de 15** combinaciones **no** son normales (α = 0,05).
2. $\Rightarrow$ el corte $|z| > 3$ no tiene sustento: se usan **Tukey fences** $Q_3 + 2 \cdot \mathrm{RIC}$.
3. **Mahalanobis robusta** (mediana y MAD) sobre las 3 variables: límite $\chi^2_{0{,}999}(3) = 16{,}27$; detecta combinaciones raras.

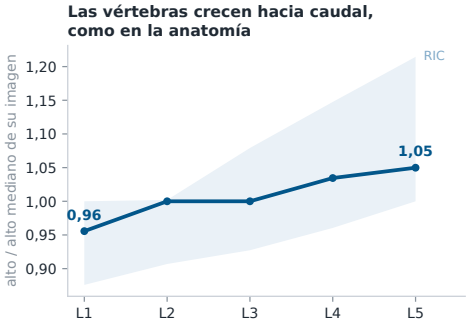
Decisión: se **marcan** con su motivo; no se descartan.



Los 5 marcados son L3: 4 por **relleno bajo** (contorno poco ajustado al cuerpo vertebral) y 1 por **área alta** respecto de sus vecinas. Van a **revisión manual**.

Anatomía coherente: 0 errores de orden





Orden craneocaudal: el centroide vertical debe crecer de L1 a L5. Detecta **etiquetas intercambiadas** entre vecinas, algo que ningún método estadístico genérico ve. Resultado: **0 violaciones**.

Progresión de tamaño: el alto relativo crece de 0,96 (L1) a 1,05 (L5), coherente con el aumento del cuerpo vertebral hacia caudal: las anotaciones son **anatómicamente plausibles**.

NHANES: los 1.709 «errores» eran imágenes giradas

Las mismas reglas de dominio, sobre 22.185 cajas

- **Duplicados:** 36 imágenes con una vértebra repetida; se conserva la caja más cerca de la posición típica.
- **Primer intento del control de orden:** marcó **1.709 cajas**. Al revisarlas, no eran errores: eran **radiografías giradas 90° o invertidas**.
- **Rediseño:** primero se detecta la **orientación** (hacia dónde se extiende la columna) y después se exige un orden monótono **a lo largo del eje**, en cualquier sentido.
- Resultado: **26 cajas en 13 imágenes** son errores reales (p. ej. L1 y L2 con la misma caja).



Para el detector

Un 11 % de NHANES está girada o invertida: hay que **normalizar la orientación** antes de entrenar.

OpenCV y exploración

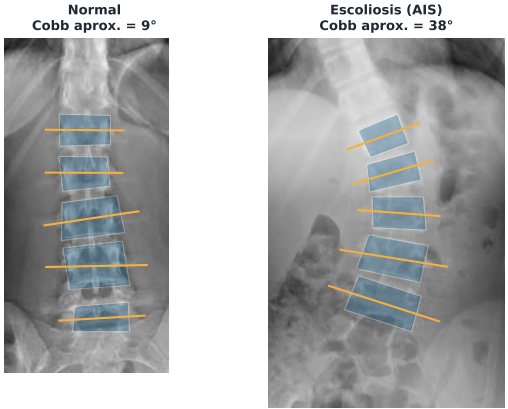
La inclinación de cada vértebra sale de su contorno

Recomendación del docente: `cv2.moments` (tutorial de momentos de OpenCV)

Descriptor	Cálculo
Área	m_{00}
Centroide	$(m_{10}/m_{00},\ m_{01}/m_{00})$
Inclinación	$\theta = \frac{1}{2}\operatorname{atan2}(2\mu_{11},\ \mu_{20} - \mu_{02})$
Excentricidad	$\sqrt{1 - \lambda_2/\lambda_1}$ (autovalores de μ)
Circularidad	$4\pi A/P^2$ (`arcLength`)
Solidez	A/A_{casco} (`convexHull`)
Hu 1, Hu 2	`HuMoments`, escala log

Validación: m_{00} coincide con el área por fórmula de Gauss (diferencia máxima $1{,}6 \times 10^{-6}$).

Cobb aproximado = máx − mín de la inclinación de L1–L5 en la imagen, la lógica del ángulo de Cobb.



En naranja, el eje principal de cada vértebra.

41 de 50 radiografías son grises guardadas como RGB

Formato de píxel y nuevas columnas

Metadatos de la imagen (`cv2.imread(…, IMREAD_UNCHANGED)`)

- 50 JPG, **3 canales, 8 bits**.
- 41 de 50 son radiografías en **gris guardadas como RGB** (los tres canales iguales).
- 50 resoluciones distintas: de 144×606 a 1669×3246 px.
- Formato, canales, profundidad de bits, tamaño y **vista** pasan a la tabla `imagen`.

Píxeles dentro de cada vértebra

Máscara con `cv2.fillPoly`: **intensidad media** y **contraste** (desvío), en [0, 1].

Columnas nuevas en los hechos

`inclinacion`, `excentricidad`, `circularidad`, `solidez`, `hu1`, `hu2`, `intensidad_media`, `contraste`

Nuevo grano: segmento intervertebral

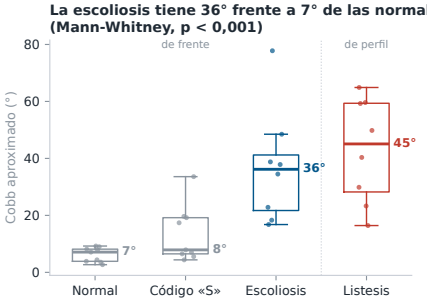
L1–L2, L2–L3, L3–L4, L4–L5 por imagen (135 segmentos): ángulo segmentario, desplazamiento y separación entre vecinas.

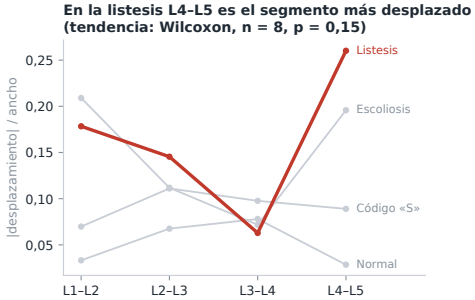
Sobre la torsión (*twist*)

La rotación axial no se mide en una radiografía 2D (requiere pedículos o tomografía). Los momentos miden la **inclinación** en el plano, base del ángulo de Cobb.

P5 · Los momentos separan escoliosis (36°) y normales (7°)

¿Los momentos de imagen detectan la patología?





Vista: escoliosis, normales y «S» son **de frente** (mide la curva); las listesis, **de perfil** (mide la lordosis).

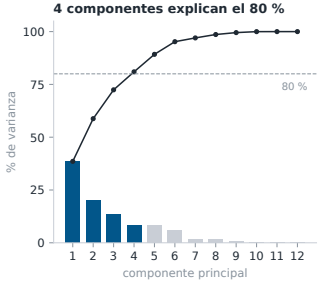
Escoliosis vs. normales: Cobb mediano **36° vs. 7°**; Mann-Whitney $p < 0{,}001$.

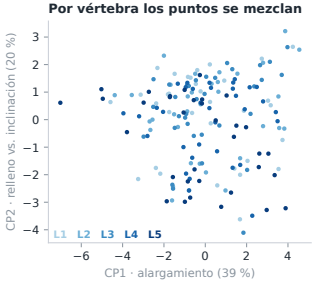
Listesis: L4–L5 es el nivel más desplazado, pero **no significativo** frente al resto (Wilcoxon, $n = 8$, $p = 0{,}15$): tendencia.

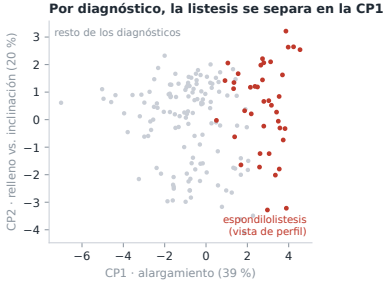
Para el CDSS: los contornos ya miden alineación.

Exploratorio (1): la forma no da el nivel, sí la vista

ACP de 12 descriptores estandarizados · 169 vértebras de Lumbar Spine







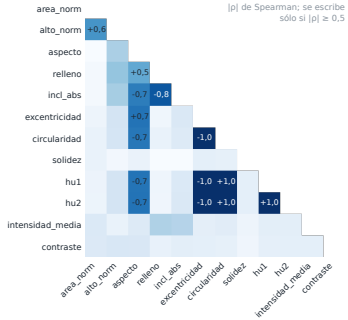
4 componentes explican el 80 %: CP1 es el **alargamiento** y CP2 el **relleno frente a la inclinación**.

Por vértebra los puntos **se mezclan**: el nivel lo da la **posición** (P3), no la forma. Por diagnóstico, la **espondilolistesis** se separa sobre la CP1.

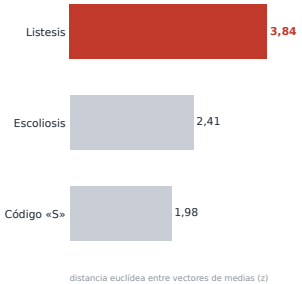
Exploratorio (2): cuatro descriptores miden lo mismo

Correlación de Spearman y distancia entre vectores de medias, como en el TP3

Excentricidad, circularidad, Hu1 y Hu2 miden lo mismo (|ρ| = 1): alcanza con una



La listesis es el perfil más lejano a la columna normal



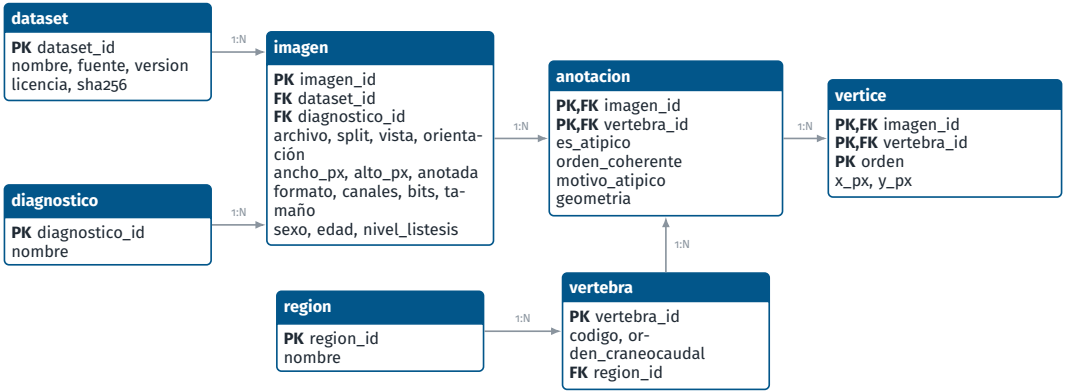
Excentricidad, circularidad, Hu1 y Hu2 tienen $|\rho| = 1$: miden lo mismo, **alcanza con una**.

La **listesis** es el perfil más lejano a la columna normal (3,84): vértebras más redondeadas, por la **vista de perfil**. El código «S» queda cerca de la escoliosis (1,73).

Base de datos transaccional

Siete tablas, dos con claves compuestas

Modelo entidad-relación de la base transaccional (SQLite)



Una sola clave por tabla. `anotacion` y `vertice` usan **claves compuestas** formadas por las tablas que conectan.

Por qué está en tercera forma normal

1FN — atomicidad

El polígono es una lista de largo variable (**grupo repetitivo**). Guardarlo como texto violaría la atomicidad: cada vértice es una fila de `vertice`.

2FN — sin dependencias parciales

Con clave (`imagen_id`, `vertebra_id`), la resolución o el sexo dependen sólo de la imagen y viven en `imagen`; el código y el orden, sólo de la vértebra. En `anotacion` quedan las marcas de calidad, que dependen del par.

3FN — sin transitivas

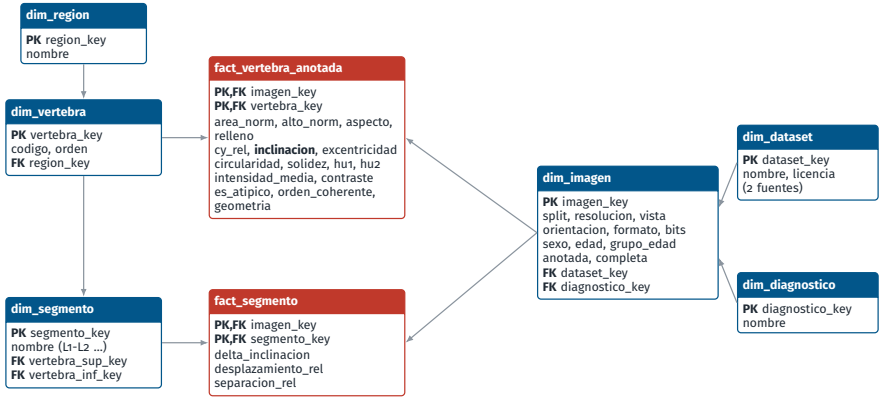
La región depende de la vértebra (`region`); el nombre del diagnóstico, de su id (`diagnostico`); la licencia y el hash, del dataset.

- **No se guardan derivados** (caja, área): se calculan desde los vértices al cargar el almacén.
- Claves foráneas activas y `foreign_key_check`: **o violaciones**; `CHECK` sobre `split`, `sexo`, `edad`.

Almacén de datos

Copo de nieve con dos tablas de hechos

Constelación de hechos: comparten dimensiones, cada una con su grano



PK compuestas por las claves de sus dimensiones en ambas tablas de hechos · `dim_segmento` se normaliza hacia `dim_vertebra` · cervical o torácica = agregar filas · miembro «sin dato» · carga desde la base transaccional.

Cada métrica del almacén responde a una pregunta

Métrica / atributo	Cálculo en el ETL	Responde
`COUNT(*)` sobre hechos	cantidad de anotaciones	**P1**
`dim_imagen.completa`	1 si la imagen tiene las 5 vértebras	**P1**
`area_norm`	área del polígono / mediana del área de las vértebras de la misma imagen	**P2, P3**
`aspecto`, `relleno`	ancho/alto de la caja; área del polígono / área de la caja	**P2**
`es_atipico`, `motivo_atipico`	marca de calidad (Tukey, Mahalanobis, orden)	**P2**
`alto_norm`, `cy_rel`	alto relativo a sus vecinas; centroide vertical / alto de la imagen	**P3**
`orden_coherente`	1 si respeta el orden L1→L5	**P3**
diagnóstico, sexo, `grupo_edad`	extraídos del nombre de archivo	**P4**
`excentricidad`, `circularidad`, `solidez`, `hu1/2`	momentos del contorno (OpenCV)	**P2**
`intensidad_media`, `contraste`	píxeles dentro del polígono (máscara OpenCV)	**P2**
`inclinacion`; Cobb aproximado	eje principal por momentos; `MAX − MIN` por imagen en la consulta	**P5**
`delta_inclinacion`, `desplazamiento_rel`, `separacion_rel`	en `fact_segmento`: ángulo, deslizamiento y espacio entre vecinas	**P5**

Resultados y veredicto

Resultados: cinco preguntas, cinco respuestas

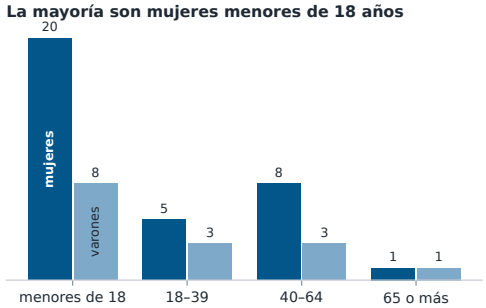
4.438
completas L1–L5 (33 + 4.405)

1,03
razón máx/mín entre clases

477
radiografías giradas o invertidas

36°
Cobb en escoliosis (7° normales)

- **P1:** Lumbar Spine sola no alcanza; con NHANES, sí.
- **P2:** calidad alta; 5 contornos a revisar.
- **P3:** orden coherente; 11 % de NHANES girada o invertida.
- **P4:** escoliosis 17, «S» 16, normales 9, listesis 8; mayoría mujeres y menores de 18.
- **P5:** Cobb aproximado 36° en escoliosis vs. 7° en normales ($p < 0{,}001$).



Veredicto: con NHANES alcanza, enderezando la orientación

Respuesta a la pregunta de investigación

Lumbar Spine sola no alcanza (33 completas, 16 % del mínimo). **Sumando NHANES sí**: 4.438 imágenes completas, con dos condiciones: **normalizar la orientación** y **sumar vistas de frente**, que hoy sólo aporta Lumbar Spine.

Próximos pasos para la tesis:

1. **Enderezar** las 477 radiografías de NHANES.
2. **Entrenar** con NHANES; **validar** con Lumbar Spine.
3. Revisar 5 contornos; anotar las 16 de escoliosis y «S».
4. Usar los contornos para la **alineación** del SINS.

Limitaciones

- El código «S» no está documentado por la fuente.
- Los metadatos dependen de la convención del nombre de archivo.
- Imagen $\neq$ paciente: no hay identificador de paciente.
- Umbral de 200 imágenes: supuesto ajustable.
- NHANES: sólo perfil, cajas estiradas, sin metadatos.
- Vista inferida del diagnóstico; *twist* no medible en 2D; $n \approx 8$ por grupo.

Uso de inteligencia artificial

Declaración

- «Claude Sonnet 4.5» para «redacción de celdas Markdown de la primera versión».
- «ChatGPT 4.5» para «sugerir esquemas SQLite de la primera versión».
- «GitHub Copilot» para «autocompletar parsing YOLO y gráficos».
- «Claude Opus 5.5» para «reestructurar el notebook: extracción sin credenciales, control de calidad, modelos con claves compuestas y tablero».
- «Claude Opus 5.5» para «implementar los momentos de OpenCV recomendados por el docente, el formato de píxel, la tabla de segmentos e integrar NHANES como segunda fuente».
- «Claude Opus 5.5» para «aplicar storytelling a gráficos y diapositivas e integrar el informe en el notebook».

Human-in-the-loop: decisiones verificadas

- Hash del zip y *Ejecutar todo* en una sesión nueva.
- Superposición de polígonos sobre la radiografía.
- Revisión manual del duplicado y de la tabla nombre $\rightarrow$ metadatos.
- Rechazo del área relativa a la imagen (49 falsos atípicos) y cambio a normalización por vecinas.
- m_{00} = área de Gauss; revisión visual de la vista por diagnóstico.
- Detección del desbordamiento `int16`.
- 1.709 «errores de orden» en NHANES: revisados, eran imágenes giradas.
- Cada métrica contrastada con P1–P5; ejes de conteo sin decimales.

¡Gracias!

Preguntas

`github.com/marcoskantor/Curso_Introduccion_Ingenieria_Datos`

Proyecto_final.ipynb · app.py · data/raw/

Anexo para el coloquio

1. Tablero
2. ETL
3. Calidad
4. OpenCV
5. BD transacc.
6. Almacén
7. Veredicto

A1 · Parsing y área del polígono

```
x = vals[0::2] * ancho_px # desnormalizar
y = vals[1::2] * alto_px
area = 0.5 * abs(np.dot(x, np.roll(y, -1))
               - np.dot(y, np.roll(x, -1)))
```

Fórmula de Gauss (*shoelace*):

$$A = \frac{1}{2}\left|\sum_{i=1}^{n}(x_i\,y_{i+1} - y_i\,x_{i+1})\right|$$

con $x_{n+1} = x_1$; `np.roll` implementa el índice cíclico.

- 4 valores ⇒ caja `xc yc w h`: se convierte a sus 4 esquinas.
- Número impar o < 6 valores ⇒ se **rechaza** la línea y se registra.
- Caja envolvente = mín/máx de los vértices; centroide = media de los vértices.
- `relleno` = área del polígono / área de la caja: 1 si el contorno es un rectángulo.

A2 · Tukey y Mahalanobis robusta

```
q1, q3 = g[var].quantile([0.25, 0.75])
lo = q1 - 2.0 * (q3 - q1)
hi = q3 + 2.0 * (q3 - q1)

rel = np.log(X / X.groupby(vertebra).median())
z = (rel - rel.median()) / MAD(rel)
d2 = z @ inv(cov(z)) @ z.T # por fila
atipico = d2 > chi2.ppf(0.999, 3) # 16.27
```

- **¿Por qué Tukey y no *z*?** Shapiro–Wilk rechaza normalidad en 10 de 15 casos: $\pm 3\sigma$ supone normalidad; los cuartiles no.
- **¿Por qué $k = 2$?** Más conservador que 1,5: con $n \approx 34$ por vértebra se evita marcar variación anatómica normal.
- **¿Por qué robusta?** Media y desvío se contaminan con los propios atípicos; mediana y MAD no.
- **¿Por qué logaritmo?** Las razones son asimétricas (0,5 y 2 están a la misma distancia de 1).

A3 · Orden craneocaudal y regla de duplicados

```
# duplicados: el mas cercano a la posicion
    esperada
anot["dist"] = (anot.cy_rel
   - anot.vertebra.map(mediana_cy)).abs()
anot = (anot.sort_values("dist")
      .drop_duplicates(["archivo", "vertebra"])
           )

# orden: cy debe crecer de L1 a L5
prev = anot.groupby("archivo").cy_rel.shift(1)
nxt = anot.groupby("archivo").cy_rel.shift(-1)
roto = (prev.notna() & (anot.cy_rel <= prev)) |
     \
     (nxt.notna() & (anot.cy_rel >= nxt))
```

- La posición vertical se normaliza por el alto de la imagen (c_y/alto) para comparar imágenes.
- La mediana por vértebra es el «lugar esperado» de esa vértebra.
- El control de orden compara cada vértebra con sus vecinas en la misma imagen (`shift` dentro del grupo).
- Supuesto: radiografías con la columna vertical (se verificó visualmente).

A4 · Carga del almacén desde la base transaccional

```
ATTACH DATABASE 'spine_oltp.db' AS oltp;
INSERT INTO dim_imagen
SELECT i.imagen_id, i.archivo, i.split, ...,
       COALESCE(i.sexo, 'sin dato'),
       CASE WHEN i.edad < 18 THEN '<18' ... END,
       COUNT(a.vertebra_id),
       CASE WHEN COUNT(a.vertebra_id) = 5
            THEN 1 ELSE 0 END, -- completa
       COALESCE(i.diagnostico_id, 0) -- miembro "
            sin dato"
FROM oltp.imagen i
LEFT JOIN oltp.anotacion a USING (imagen_id)
GROUP BY i.imagen_id;
```

- `LEFT JOIN`: las imágenes sin anotar también entran a la dimensión (P1 las necesita).
- Hechos: métricas recalculadas desde `vertice`, la fuente de verdad.
- `area_norm` y `alto_norm` se calculan con la mediana **por imagen** (`groupby + transform`).
- Validación: conteos por tabla y `PRAGMA foreign_key_check`.

A5 · Momentos y Cobb aproximado

```
cnt = np.column_stack([x, y]).astype(np.float32)
m = cv2.moments(cnt.reshape(-1, 1, 2))
mu20 = m["mu20"] / m["m00"]
mu02 = m["mu02"] / m["m00"]
mu11 = m["mu11"] / m["m00"]
theta = 0.5 * np.degrees(np.arctan2(2*mu11, mu20
    - mu02))
```

```
SELECT imagen_key,
     MAX(inclinacion) - MIN(inclinacion) AS
          cobb_aprox
FROM fact_vertebra_anotada
GROUP BY imagen_key HAVING COUNT(*) >= 4;
```

- Los momentos centrales μ_{pq} son la «covarianza» del contorno: su eje principal es la dirección de máxima dispersión.
- Divididos por m_{00} no dependen del tamaño de la vértebra.
- `atan2` resuelve el cuadrante; el ½ viene de la fórmula del ángulo doble.
- Pruebas no paramétricas porque $n \approx 8$ y no hay normalidad.