ITBA

(2026Q) DIA.04
Introducción a la Ingeniería de Datos
Comisión A

¿Alcanzan los datos públicos de radiografías lumbares para entrenar el detector de vértebras de un CDSS de inestabilidad espinal?

Proyecto Final — Defensa académica

Marcos Kantor
Director: Ramiro M. Irastorza (IFLySiB-CONICET)
Codirector: Marcelo A. Cappelletti (LEICI-CONICET, UNAJ)

La respuesta, antes que la evidencia

Idea principal de la exposición

En una oración

Los datos públicos **alcanzan** para entrenar el detector de vértebras L1–L5 **sólo si se combinan dos fuentes**: NHANES aporta el volumen y Lumbar Spine la forma, la clínica y las vistas de frente. Antes hay que **enderezar el 11 %** de NHANES.

33
completas en Lumbar Spine: no alcanza

4.405
completas en NHANES

477
radiografías giradas o invertidas

36°
de Cobb en escoliosis (7° en normales)

Lo que sigue es la evidencia: extracción, calidad, modelado y tablero.

La pregunta

El **SINS** (*Spinal Instability Neoplastic Score*) se evalúa **vértebra por vértebra**: localización, alineación, colapso, compromiso posterior.

La primera etapa de un CDSS que lo asista es **encontrar y delimitar cada vértebra**.

Pregunta de investigación

¿El dataset público *Lumbar Spine* tiene la cobertura, el balance, la calidad geométrica y la coherencia anatómica necesarias para entrenar el detector L1–L5?

	Preguntas de análisis (guían el almacén y el tablero)
P1	**Cobertura y balance:** ¿cuántas imágenes tienen L1–L5 completas? ¿están balanceadas las clases? ¿Y sumando una segunda fuente?
P2	**Calidad geométrica:** ¿qué anotaciones tienen tamaño o forma atípicos para su vértebra?
P3	**Coherencia anatómica:** ¿se respeta el orden L1→L5 y el aumento de tamaño hacia caudal?
P4	**Representatividad:** ¿qué diagnósticos, sexos y edades cubre?
P5	**Alineación:** ¿la inclinación y el desplazamiento medidos con momentos de imagen distinguen las patologías?

Dos fuentes: Lumbar Spine da la forma, NHANES el volumen

Roboflow Universe · licencia CC BY 4.0 · la segunda entra como nueva fila en `dataset`



Lumbar Spine (rp-team, v1) — polígonos

50	34	170
radiografías	anotadas	polígonos

NHANES L1–L5 (`main-kybbe`) — cajas; sólo la anotación COCO

4.436	22.185
radiografías de perfil	cajas L1–L5

- El **nombre de archivo** de Lumbar Spine codifica diagnóstico, sexo y edad (⇒ expresiones regulares, P4): `N18-Olisthesis-L4-5-F-56-Yrs`.
- NHANES responde **P1 y P3**; **no** P2, P4 ni P5: una caja no tiene forma ni inclinación, y no trae metadatos clínicos.

El tablero responde primero: con dos fuentes, alcanza

Streamlit · lee sólo del almacén `spine_dw.db` · en Colab se abre al final del notebook



Cómo leerlo

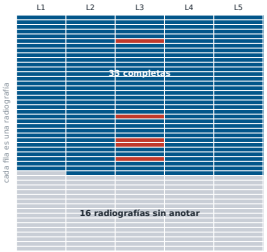
Arriba, la pregunta. Debajo, cinco indicadores, un **veredicto en color** (rojo = no alcanza, amarillo = ajuste fino, verde = apto) y la tabla por fuente.

Qué nos dice

Con las dos fuentes hay **4.438 imágenes completas**: apto. Si se deja sólo Lumbar Spine (filtro «Fuente»), vuelve el rojo: 33 no alcanzan. El mínimo (200) es un supuesto ajustable.

P1 y P2 · Cobertura y calidad geométrica

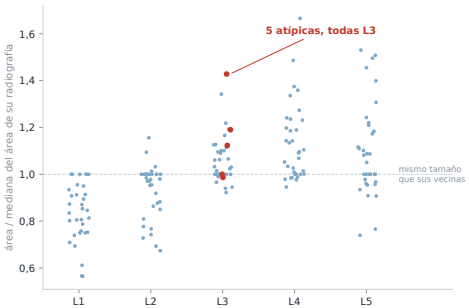
Tablero · 33 completas en Lumbar Spine; 5 de 169 contornos atípicos



P1 · cada fila, una radiografía



P1 · completas por fuente



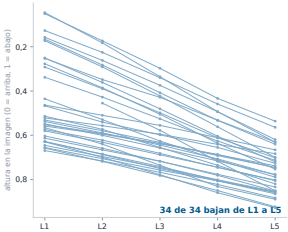
P2 · cada punto, una vértebra (rojo = atípica)

Qué nos dice

P1: Lumbar Spine 33 completas y 16 sin anotar; NHANES **4.405**; sumadas superan el mínimo. **P2:** sólo **5 de 169** contornos atípicos, todos L3: no se borran, se listan con su motivo para **revisarlos a mano**.

P3 y P5 · Anatomía coherente y curva medible

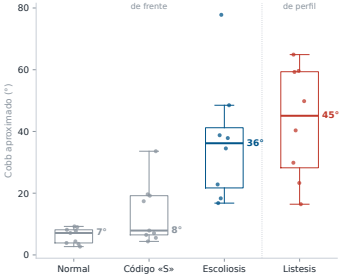
Tablero · coherencia anatómica y alineación



P3 · cada línea, una radiografía (L1 → L5)



P3 · orientación de las radiografías



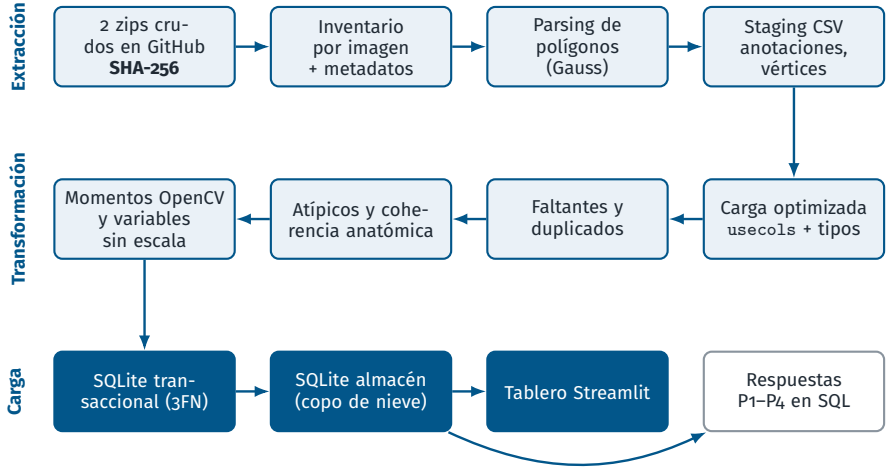
P5 · Cobb aproximado por radiografía

Qué nos dice

P3: Lumbar Spine 0 errores; NHANES **477 giradas o invertidas** (11 %) y sólo 26 cajas mal etiquetadas. **P5:** Cobb mediano **36° en escoliosis vs. 7° en normales** (Mann–Whitney $p < 0{,}001$); en listesis, L4–L5 es el nivel más desplazado, sin significancia ($n = 8$).

De dos zips públicos a un tablero, sin credenciales

Pipeline de extracción, transformación y carga



Faltantes no aleatorios y un solo duplicado

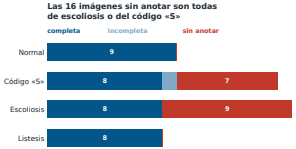
Se descarta sólo lo imposible; lo raro se marca

Nivel	Qué falta	Decisión
Imagen	16 de 50 sin anotaciones	**se conservan** (`anotada = 0`)
Vértebra	imagen sin alguna de L1–L5	se mide la **completitud**
Atributo	coordenadas o clase inválidas (0)	**descarte**
Metadato	sexo no identificable (1)	**nulo**, sin imputar

No se imputa geometría ni datos clínicos: inventaría vértebras o pacientes.

Duplicado: en `N20-S-79-F` la L2 aparece dos veces; se conserva la más cercana a la posición mediana de L2: 170 → **169** anotaciones.

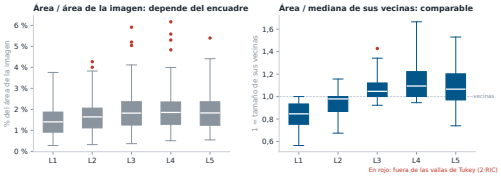




Hallazgo

Las 16 imágenes sin anotar son **todas** de escoliosis (9) o del código «S» (7): el faltante **no es aleatorio** (MNAR). Descartarlas sin registrarlo ocultaría un sesgo de cobertura.

Atípicos: la variable equivocada inventa 49



Primer intento: área / área de la imagen marcó **49 de 169**: era el *encuadre* (recorte lumbar vs. columna completa).

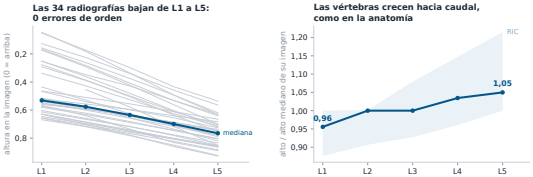
Decisión: normalizar **dentro de cada imagen** (área / mediana de sus vecinas) ⇒ **5 de 169**.



1. **Shapiro–Wilk:** 10 de 15 combinaciones **no** son normales ⇒ el corte $|z| > 3$ no tiene sustento.
2. **Tukey** $Q_3 + 2 \cdot \mathrm{RIC}$ y **Mahalanobis robusta** (mediana y MAD; $\chi^2_{0{,}999}(3) = 16{,}27$).
3. Los 5 son L3: 4 por **relleno bajo** y 1 por **área alta**. Se marcan, no se descartan.

Anatomía coherente; los «errores» de NHANES eran giros

Lumbar Spine (169 polígonos) y NHANES (22.185 cajas)



Orden craneocaudal: el centroide vertical debe crecer de L1 a L5; detecta etiquetas intercambiadas. Lumbar Spine: **0 violaciones**. El alto relativo crece de 0,96 (L1) a 1,05 (L5): anotaciones **anatómicamente plausibles**.

NHANES, mismas reglas a escala

- 36 imágenes con una vértebra duplicada: se conserva la caja más cercana a la posición típica.
- Primer control de orden: **1.709 cajas**. No eran errores: eran radiografías **giradas 90° o invertidas**.
- Rediseño: se detecta la **orientación** y se exige orden monótono a lo largo del eje. Resultado: **26 cajas en 13 imágenes**.

Para el detector

11 % de NHANES girada o invertida: **normalizar la orientación** antes de entrenar.

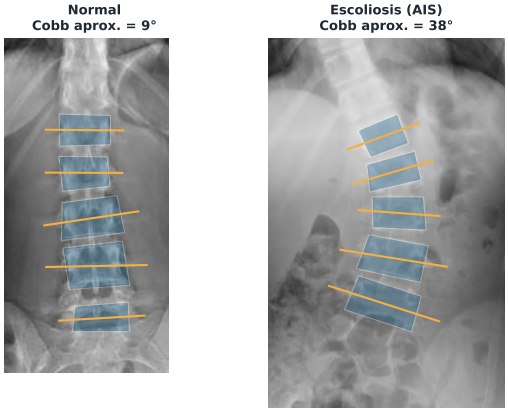
La inclinación de cada vértebra sale de su contorno

Recomendación del docente: `cv2.moments` (tutorial de momentos de OpenCV)

Descriptor	Cálculo
Área	m_{00}
Centroide	$(m_{10}/m_{00},\ m_{01}/m_{00})$
Inclinación	$\theta = \frac{1}{2}\,\mathrm{atan2}(2\mu_{11},\ \mu_{20} - \mu_{02})$
Excentricidad	$\sqrt{1 - \lambda_2/\lambda_1}$ (autovalores de μ)
Circularidad	$4\pi A/P^2$ (`arcLength`)
Solidez	A/A_{casco} (`convexHull`)
Hu 1, Hu 2	`HuMoments`, escala log

Validación: m_{00} coincide con el área por fórmula de Gauss (diferencia máxima $1{,}6 \times 10^{-6}$).

Cobb aproximado = máx − mín de la inclinación de L1–L5 en la imagen, la lógica del ángulo de Cobb.



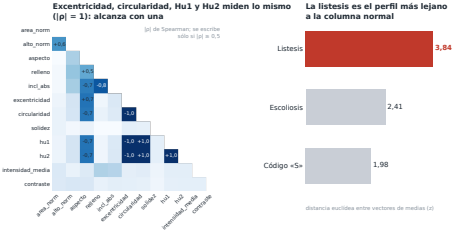
En naranja, el eje principal de cada vértebra.

Exploratorio: la forma no da el nivel, sí la vista

Herramientas del TP3 sobre 12 descriptores estandarizados · 169 vértebras de Lumbar Spine



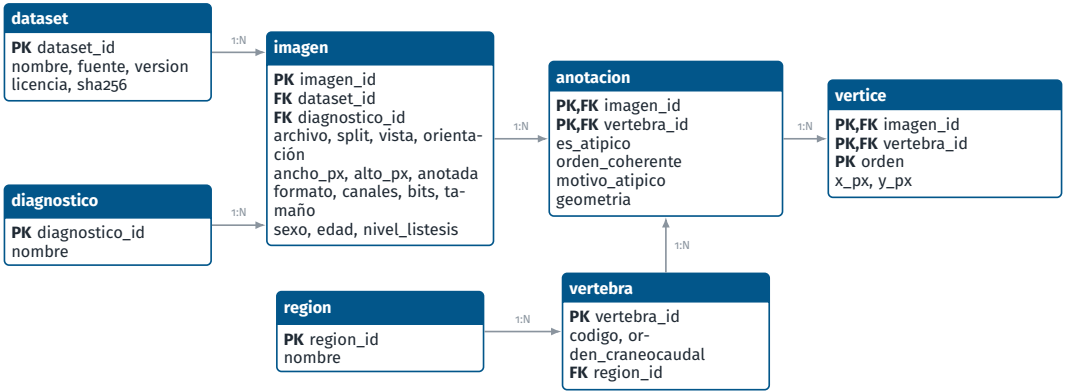
4 componentes explican el 80 %: CP1 = **alargamiento**, CP2 = relleno frente a inclinación. Por vértebra los puntos **se mezclan** (el nivel lo da la posición, P3); la **espondilolistesis** se separa sobre CP1.



Excentricidad, circularidad, Hu1 y Hu2 tienen $|\rho| = 1$: **alcanza con una**. La **listesis** es el perfil más lejano a la columna normal (3,84), por la **vista de perfil**.

Siete tablas, dos con claves compuestas

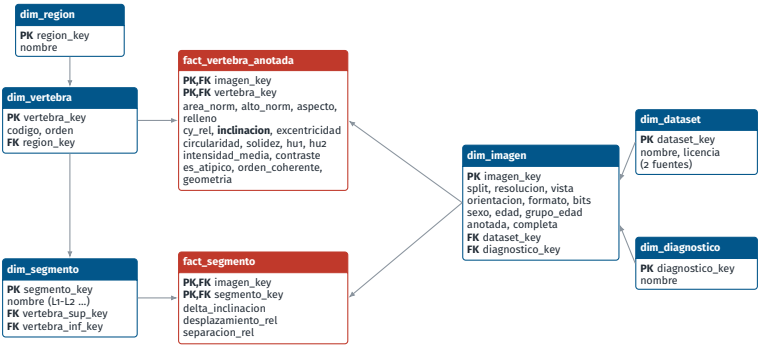
Modelo entidad-relación de la base transaccional (SQLite)



Una sola clave por tabla; `anotacion` y `vertice` usan **claves compuestas**. 3FN: el polígono es un grupo repetitivo ($\Rightarrow$ una fila por vértice), nada depende de media clave y no se guardan derivados (anexo B17).

Copo de nieve con dos tablas de hechos

Constelación de hechos: comparten dimensiones, cada una con su grano



Grano: `fact_vertebra_anotada` = una vértebra en una imagen; `fact_segmento` = un segmento intervertebral en una imagen. Medidas atómicas (los promedios se calculan al consultar) · PK compuestas por las claves de sus dimensiones en ambas tablas de hechos.

Cada métrica del almacén responde a una pregunta

Métrica / atributo	Cálculo en el ETL	Responde
`COUNT(*)` sobre hechos	cantidad de anotaciones	**P1**
`dim_imagen.completa`	1 si la imagen tiene las 5 vértebras	**P1**
`area_norm`	área del polígono / mediana del área de las vértebras de la misma imagen	**P2**, **P3**
`aspecto`, `relleno`	ancho/alto de la caja; área del polígono / área de la caja	**P2**
`es_atipico`, `motivo_atipico`	marca de calidad (Tukey, Mahalanobis, orden)	**P2**
`alto_norm`, `cy_rel`	alto relativo a sus vecinas; centroide vertical / alto de la imagen	**P3**
`orden_coherente`	1 si respeta el orden L1→L5	**P3**
diagnóstico, sexo, `grupo_edad`	extraídos del nombre de archivo	**P4**
`excentricidad`, `circularidad`, `solidez`, `hu1/2`	momentos del contorno (OpenCV)	**P2**
`intensidad_media`, `contraste`	píxeles dentro del polígono (máscara OpenCV)	**P2**
`inclinacion`; Cobb aproximado	eje principal por momentos; `MAX − MIN` por imagen en la consulta	**P5**
`delta_inclinacion`, `desplazamiento_rel`, `separacion_rel`	en `fact_segmento`: ángulo, deslizamiento y espacio entre vecinas	**P5**

Veredicto: con NHANES alcanza, enderezando la orientación

Respuesta a la pregunta de investigación

Lumbar Spine sola no alcanza (33 completas, 16 % del mínimo). **Sumando NHANES sí**: 4.438 imágenes completas, con dos condiciones: **normalizar la orientación** y **sumar vistas de frente**, que hoy sólo aporta Lumbar Spine.

Próximos pasos para la tesis:

1. **Enderezar** las 477 radiografías de NHANES.
2. **Entrenar** con NHANES; **validar** con Lumbar Spine.
3. Revisar 5 contornos; anotar las 16 de escoliosis y «S».
4. Usar los contornos para la **alineación** del SINS.

Limitaciones

- El código «S» no está documentado por la fuente.
- Los metadatos dependen de la convención del nombre de archivo.
- Imagen $\neq$ paciente: no hay identificador de paciente.
- Umbral de 200 imágenes: supuesto ajustable.
- NHANES: sólo perfil, cajas estiradas, sin metadatos.
- Vista inferida del diagnóstico; *twist* no medible en 2D; $n \approx 8$ por grupo.

Uso de inteligencia artificial

Declaración

- «Claude Sonnet 4.5» para «redacción de celdas Markdown de la primera versión».
- «ChatGPT 4.5» para «sugerir esquemas SQLite de la primera versión».
- «GitHub Copilot» para «autocompletar parsing YOLO y gráficos».
- «Claude Opus 5.5» para «reestructurar el notebook: extracción sin credenciales, control de calidad, modelos con claves compuestas y tablero».
- Prompts **guiados** (contexto, grano y pedido concreto) en lugar de pedidos vagos: ver informe.
- «Claude Opus 5.5» para «implementar los momentos de OpenCV recomendados por el docente, el formato de píxel, la tabla de segmentos e integrar NHANES como segunda fuente».
- «Claude Opus 5.5» para «aplicar storytelling a gráficos y diapositivas e integrar el informe en el notebook».

Human-in-the-loop: decisiones verificadas

- Hash del zip y *Ejecutar todo* en una sesión nueva.
- Superposición de polígonos sobre la radiografía.
- Revisión manual del duplicado y de la tabla nombre $\rightarrow$ metadatos.
- Rechazo del área relativa a la imagen (49 falsos atípicos) y cambio a normalización por vecinas.
- m_{00} = área de Gauss; revisión visual de la vista por diagnóstico.
- Detección del desbordamiento `int16`.
- 1.709 «errores de orden» en NHANES: revisados, eran imágenes giradas.
- Cada métrica contrastada con P1–P5; ejes de conteo sin decimales.

¡Gracias!

Preguntas

`github.com/marcoskantor/Curso_Introduccion_Ingenieria_Datos`

Proyecto_final.ipynb · app.py · data/raw/

Anexo: detalle de las diapositivas condensadas

Estas diapositivas **no se presentan**: quedan para el coloquio. Contienen lo que se quitó de la exposición para ajustarla a 20 minutos.

Anexo	Contenido
B1–B3	Recorrido; Lumbar Spine y NHANES en detalle
B4–B7	Tablero: P1, P3, P2 y P4/P5 por separado
B8–B9	Extracción reproducible y carga optimizada; duplicados e inválidos
B10–B13	Atípicos (variable y criterio); anatomía; control de calidad de NHANES
B14–B16	Formato de píxel; P5 completo; perfiles y redundancia
B17–B19	Normalización (1FN/2FN/3FN); resultados P1–P5; prompts guiados de IA
A1–A5	Código: parsing y área, Tukey/Mahalanobis, orden y duplicados, carga del almacén, momentos

B1 · Recorrido de la exposición

1. Pregunta de investigación y dataset
2. **Demostración del tablero**
3. Proceso de ETL
4. Datos faltantes y anomalías
5. **Descriptores de forma con OpenCV** y análisis exploratorio
6. Modelo entidad-relación transaccional
7. Diseño del almacén de datos
8. Resultados y veredicto

Artefactos (repositorio GitHub del curso)

`Proyecto_final.ipynb` — Colab reproducible
`spine_oltp.db` — SQLite transaccional
`spine_dw.db` — SQLite almacén
`app.py` — tablero Streamlit
`data/raw/…zip` — dato crudo (CC BY 4.0)

Se ejecuta con *Entorno de ejecución → Ejecutar todo*, sin credenciales ni archivos subidos a mano.

B2 · Lumbar Spine: pocos datos, con contornos y clínica

rp-team, Roboflow Universe, versión 1, licencia CC BY 4.0



50 radiografías

34 anotadas

170 polígonos

5 clases L1–L5

- Polígonos: cada línea es `clase x1 y1 … xn yn` en $[0, 1]$.
- De **144**×**725** a **1669**×**3246** px: recortes lumbares y columnas completas.
- El **nombre de archivo codifica datos clínicos**:

  `N18-Olisthesis-L4-5-F-56-Yrs_jpg.rf.<hash>.jpg`

  diagnóstico · sexo · edad ⇒ expresiones regulares (P_4).
- La espondilolistesis es pertinente para el criterio de **alineación** del SINS.

B3 · NHANES multiplica el volumen, pero con cajas y de perfil

Segunda fuente para responder P1, P3 y el veredicto

4.436 radiografías de perfil

22.185 cajas L1–L5

- Radiografías lumbares de la encuesta nacional de salud **NHANES** (EE. UU.), anotadas en Roboflow Universe (`main-kybbe`), **CC BY 4.0**.
- Anotadas con **cajas**, no polígonos, y estiradas a 640×640 por la fuente.
- Se publica en GitHub **sólo la anotación COCO** (542 KB): P1 necesita qué vértebras hay, no los píxeles.

Qué responde y qué no

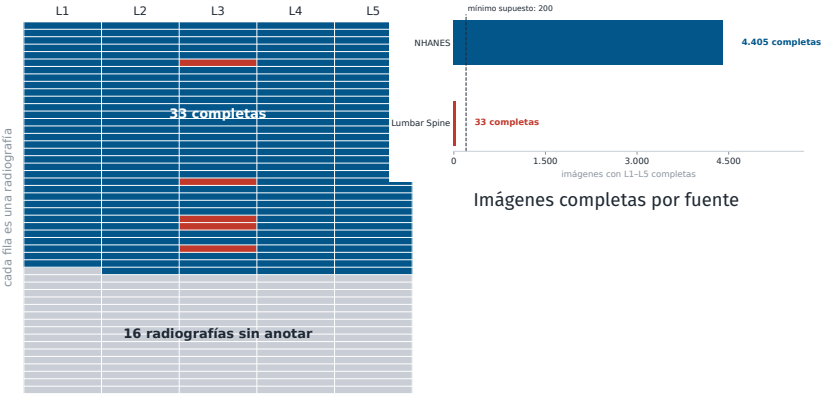
Sí: P1 (cobertura y veredicto) y P3 (orden y orientación).

No: P2 y P5. Una caja alineada con los ejes no tiene forma ni inclinación; P4 tampoco, porque no trae metadatos clínicos.

Se integra al mismo modelo: nueva fila en `dataset`, `imagen.dataset_id` y `anotacion.geometria = caja`.

B4 · P1 · Lumbar Spine sola no alcanza: 33 imágenes completas

Tablero · ¿cuántas imágenes tienen L1–L5 completas?



Imágenes completas por fuente

Cómo leerlo

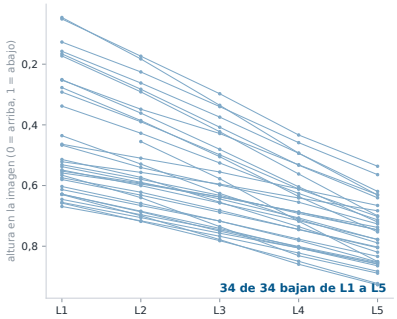
Izquierda (Lumbar Spine): **cada fila es una radiografía**; azul = anotada, rojo = atípica, gris = falta. Derecha: completas por fuente y el mínimo.

Qué nos dice

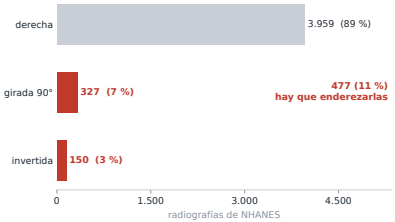
Lumbar Spine: 33 completas y **16 sin anotar**. NHANES: **4.405**. Sumadas superan el mínimo.

B5 · P3 · La anatomía se respeta; el problema es la orientación

Tablero · ¿las anotaciones respetan el orden L1→L5?



Posición de cada vértebra en su radiografía



Orientación de las radiografías

Cómo leerlo

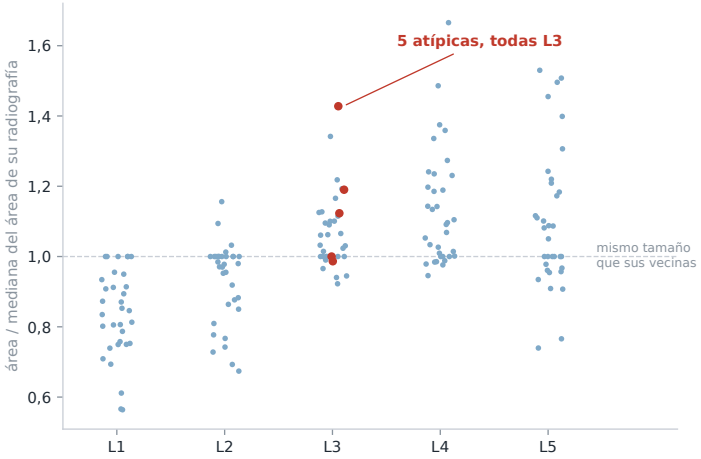
Izquierda (Lumbar Spine): **cada línea es una radiografía**; debe bajar de L1 a L5. Derecha (NHANES): en rojo, las que hay que enderezar.

Qué nos dice

Lumbar Spine: 0 errores. NHANES: **477 giradas o invertidas** (11 %) y sólo 26 cajas mal etiquetadas.

B6 · P2 · Sólo 5 de 169 contornos son atípicos

Tablero · ¿hay anotaciones mal dibujadas?



Cómo leerlo

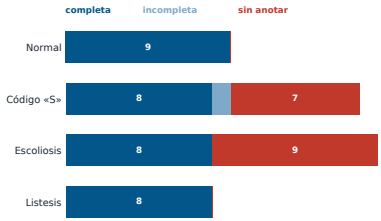
Cada punto es una vértebra anotada. 1 = mismo tamaño que las otras vértebras de su radiografía. En rojo, las que el control estadístico marcó como atípicas.

Qué nos dice

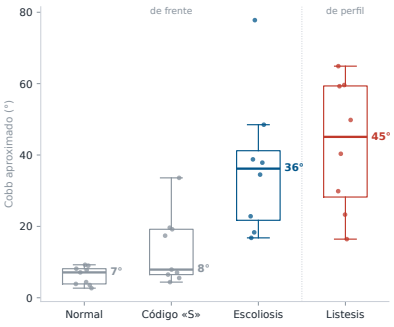
Sólo **5 de 169**, todas L3. No se borran: el tablero las lista con su motivo para **revisarlas a mano**.

B7 · P4 y P5 · Faltan escoliosis, pero el contorno mide la curva

Tablero · ¿qué cubre el dataset y qué se puede medir?



P4 · Imágenes por diagnóstico



P5 · Cobb aproximado por radiografía

Cómo leerlo

Izquierda: azul = completa, rojo = sin anotar. Derecha: **cada punto es una radiografía**; cuanto más alto, más inclinadas entre sí están sus vértebras.

Qué nos dice

Las sin anotar son escoliosis y «S». Escoliosis: **36°**; normales: **7°**. La curva se mide desde el contorno.

B8 · Extracción verificada; carga con 88 % menos memoria

Extracción sin credenciales

- Roboflow exige cuenta y API key ⇒ no es *estrictamente reproducible*.
- La licencia **CC BY 4.0** permite redistribuir: el zip crudo se publicó **sin modificar** en `data/raw/`.
- Descarga por URL pública + verificación **SHA-256**: todos obtienen los mismos bytes.
- Proceso **idempotente**: si el archivo está y el hash coincide, no se vuelve a bajar.
- El SDK de Roboflow queda como alternativa opcional.

Elección de columnas y tipado

Variable	Tipo
`clase_id`, `linea`	`int8`
`ancho_px`, `n_vertices`	`int16`
`edad` (puede faltar)	`Int8` *nullable*
coordenadas, áreas	`float32`
`archivo`, `split`, `sexo`	`category`

Tabla de staging	Filas	Ahorro
imágenes	50	67 %
anotaciones	170	71 %
vértices	681	88 %

Ojo: `ancho*alto` en `int16` se desborda ⇒ `float` antes de multiplicar.

B9 · Se descarta sólo lo imposible: 1 duplicado y 0 inválidos

Duplicados e inválidos geométricos

Duplicados

El grano esperado es **una anotación por (imagen, vértebra)**. En `N20-S-79-F` la **L2 aparece dos veces**.

Regla: se conserva la que está más cerca de la posición vertical mediana de L2 en todo el dataset.

Línea	c_y/alto	dist. a mediana	
3	0,455	0,118	**se conserva**
4	0,345	0,229	descarte

Resultado: 170 → **169** anotaciones; la imagen queda incompleta (4 vértebras).

Reglas de dominio

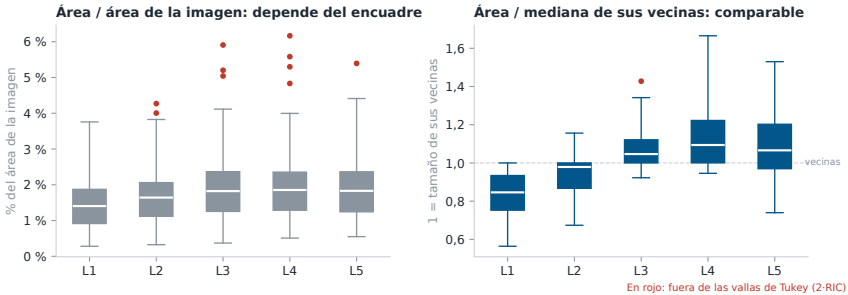
- Polígono fuera de la imagen más de un 2 % ⇒ **descarte**.
- Desborde menor (redondeo del anotador) ⇒ **recorte** al borde.
- Área < 1 px^2 o menos de 3 vértices ⇒ **descarte**.

Resultado: **0 casos**; quedan como control para futuras versiones.

Criterio: se descarta sólo lo imposible; lo raro se marca.

B10 · Atípicos (1): la variable equivocada inventa 49 atípicos

El área relativa a la imagen depende del encuadre; la relativa a sus vecinas, no



Primer intento: área / área de la imagen. Marcó **49 de 169** anotaciones: *imágenes enteras*, porque una es un recorte lumbar y otra una columna completa.

Decisión: normalizar **dentro de cada imagen**: `area_norm` = área / mediana del área de sus vecinas.
Atípicos: **5 de 169** — una vértebra es rara si no se parece a sus vecinas.

B11 · Atípicos (2): sin normalidad, Tukey y Mahalanobis robusta

Variables por vértebra: `area_norm`, `aspecto` (ancho/alto), `relleno` (área del polígono / área de la caja).

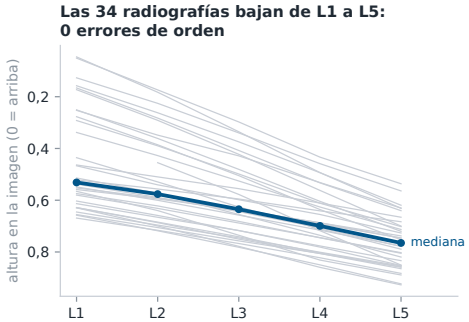
1. **Shapiro–Wilk** por vértebra (n ≈ 34): **10 de 15** combinaciones **no** son normales (α = 0,05).
2. $\Rightarrow$ el corte $|z| > 3$ no tiene sustento: se usan **Tukey fences** $Q_3 + 2 \cdot \mathrm{RIC}$.
3. **Mahalanobis robusta** (mediana y MAD) sobre las 3 variables: límite $\chi^2_{0{,}999}(3) = 16{,}27$; detecta combinaciones raras.

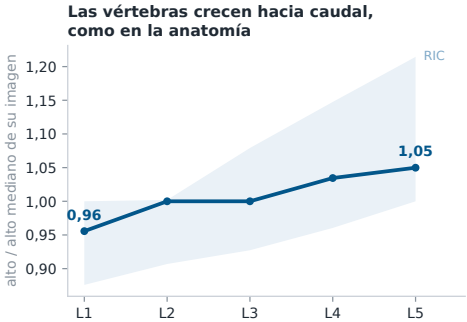
Decisión: se **marcan** con su motivo; no se descartan.



Los 5 marcados son L3: 4 por **relleno bajo** (contorno poco ajustado al cuerpo vertebral) y 1 por **área alta** respecto de sus vecinas. Van a **revisión manual**.

B12 · Anatomía coherente: 0 errores de orden





Orden craneocaudal: el centroide vertical debe crecer de L1 a L5. Detecta **etiquetas intercambiadas** entre vecinas, algo que ningún método estadístico genérico ve. Resultado: **0 violaciones**.

Progresión de tamaño: el alto relativo crece de 0,96 (L1) a 1,05 (L5), coherente con el aumento del cuerpo vertebral hacia caudal: las anotaciones son **anatómicamente plausibles**.

B13 · NHANES: los 1.709 «errores» eran imágenes giradas

Las mismas reglas de dominio, sobre 22.185 cajas

- **Duplicados:** 36 imágenes con una vértebra repetida; se conserva la caja más cerca de la posición típica.
- **Primer intento del control de orden:** marcó **1.709 cajas**. Al revisarlas, no eran errores: eran **radiografías giradas 90° o invertidas**.
- **Rediseño:** primero se detecta la **orientación** (hacia dónde se extiende la columna) y después se exige un orden monótono **a lo largo del eje**, en cualquier sentido.
- Resultado: **26 cajas en 13 imágenes** son errores reales (p. ej. L1 y L2 con la misma caja).



Para el detector

Un 11 % de NHANES está girada o invertida: hay que **normalizar la orientación** antes de entrenar.

B14 · 41 de 50 radiografías son grises guardadas como RGB

Formato de píxel y nuevas columnas

Metadatos de la imagen (`cv2.imread(…, IMREAD_UNCHANGED)`)

- 50 JPG, **3 canales, 8 bits**.
- 41 de 50 son radiografías en **gris guardadas como RGB** (los tres canales iguales).
- 50 resoluciones distintas: de 144×606 a 1669×3246 px.
- Formato, canales, profundidad de bits, tamaño y **vista** pasan a la tabla `imagen`.

Píxeles dentro de cada vértebra

Máscara con `cv2.fillPoly`: **intensidad media** y **contraste** (desvío), en [0, 1].

Columnas nuevas en los hechos

`inclinacion`, `excentricidad`, `circularidad`, `solidez`, `hu1`, `hu2`, `intensidad_media`, `contraste`

Nuevo grano: segmento intervertebral

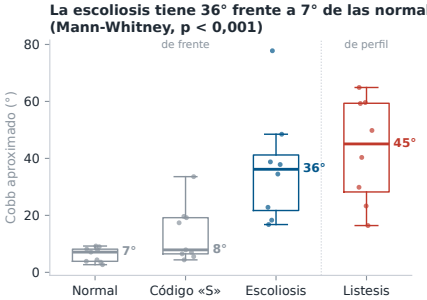
L1–L2, L2–L3, L3–L4, L4–L5 por imagen (135 segmentos): ángulo segmentario, desplazamiento y separación entre vecinas.

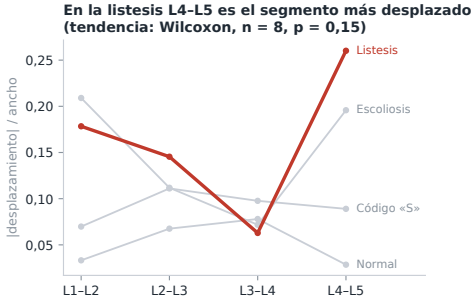
Sobre la torsión (*twist*)

La rotación axial no se mide en una radiografía 2D (requiere pedículos o tomografía). Los momentos miden la **inclinación** en el plano, base del ángulo de Cobb.

B15 · P5 · Los momentos separan escoliosis (36°) y normales (7°)

¿Los momentos de imagen detectan la patología?





Vista: escoliosis, normales y «S» son **de frente** (mide la curva); las listesis, **de perfil** (mide la lordosis).

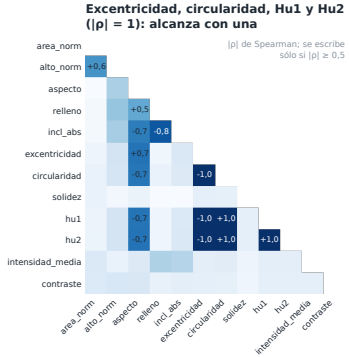
Escoliosis vs. normales: Cobb mediano **36° vs. 7°**; Mann-Whitney $p < 0{,}001$.

Listesis: L4–L5 es el nivel más desplazado, pero **no significativo** frente al resto (Wilcoxon, $n = 8$, $p = 0{,}15$): tendencia.

Para el CDSS: los contornos ya miden alineación.

B16 · Exploratorio (2): cuatro descriptores miden lo mismo

Correlación de Spearman y distancia entre vectores de medias, como en el TP3





Excentricidad, circularidad, Hu1 y Hu2 tienen $|\rho| = 1$: miden lo mismo, **alcanza con una**.

La **listesis** es el perfil más lejano a la columna normal (3,84): vértebras más redondeadas, por la **vista de perfil**. El código «S» queda cerca de la escoliosis (1,73).

B17 · Por qué está en tercera forma normal

1FN — atomicidad

El polígono es una lista de largo variable (**grupo repetitivo**). Guardarlo como texto violaría la atomicidad: cada vértice es una fila de `vertice`.

2FN — sin dependencias parciales

Con clave (`imagen_id`, `vertebra_id`), la resolución o el sexo dependen sólo de la imagen y viven en `imagen`; el código y el orden, sólo de la vértebra. En `anotacion` quedan las marcas de calidad, que dependen del par.

3FN — sin transitivas

La región depende de la vértebra (`region`); el nombre del diagnóstico, de su id (`diagnostico`); la licencia y el hash, del dataset.

- **No se guardan derivados** (caja, área): se calculan desde los vértices al cargar el almacén.
- Claves foráneas activas y `foreign_key_check`: **o violaciones**; `CHECK` sobre `split`, `sexo`, `edad`.

B18 · Resultados: cinco preguntas, cinco respuestas

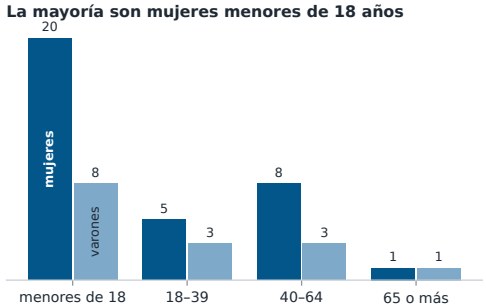
4.438
completas L1–L5 (33 + 4.405)

1,03
razón máx/mín entre clases

477
radiografías giradas o invertidas

36°
Cobb en escoliosis (7° normales)

- **P1:** Lumbar Spine sola no alcanza; con NHANES, sí.
- **P2:** calidad alta; 5 contornos a revisar.
- **P3:** orden coherente; 11 % de NHANES girada o invertida.
- **P4:** escoliosis 17, «S» 16, normales 9, listesis 8; mayoría mujeres y menores de 18.
- **P5:** Cobb aproximado 36° en escoliosis vs. 7° en normales ($p < 0{,}001$).



B19 · Prompts guiados: contexto, grano y pedido

En lugar de pedidos vagos que obligan a la IA a adivinar el modelo

Estructura

1. **Contexto:** qué es cada entidad (imagen, vértebra, anotación, segmento) y cómo se relacionan.
2. **Grano:** la unidad de cada tabla de hechos.
3. **Pedido concreto:** qué consultas o revisión se quiere.

Vago: «generá las consultas del almacén».

Ejemplo

Contexto. Una imagen es una radiografía; una vértebra es L1 a L5; una anotación es el contorno de una vértebra en una imagen; un segmento es un par de vértebras consecutivas.

Grano. `fact_vertebra_anotada`: una vértebra en una imagen; `fact_segmento`: un segmento en una imagen. Medidas atómicas, sin promedios guardados.

Pedido. Creá las consultas para este diseño de almacén (`COUNT`/`SUM` de completas y atípicas, `AVG` al consultar, Cobb aproximado).

A1 · Parsing y área del polígono

```
x = vals[0::2] * ancho_px # desnormalizar
y = vals[1::2] * alto_px
area = 0.5 * abs(np.dot(x, np.roll(y, -1))
               - np.dot(y, np.roll(x, -1)))
```

Fórmula de Gauss (*shoelace*):

$$A = \frac{1}{2}\left|\sum_{i=1}^{n}(x_i\,y_{i+1} - y_i\,x_{i+1})\right|$$

con $x_{n+1} = x_1$; `np.roll` implementa el índice cíclico.

- 4 valores ⇒ caja `xc yc w h`: se convierte a sus 4 esquinas.
- Número impar o < 6 valores ⇒ se **rechaza** la línea y se registra.
- Caja envolvente = mín/máx de los vértices; centroide = media de los vértices.
- `relleno` = área del polígono / área de la caja: 1 si el contorno es un rectángulo.

A2 · Tukey y Mahalanobis robusta

```
q1, q3 = g[var].quantile([0.25, 0.75])
lo = q1 - 2.0 * (q3 - q1)
hi = q3 + 2.0 * (q3 - q1)

rel = np.log(X / X.groupby(vertebra).median())
z = (rel - rel.median()) / MAD(rel)
d2 = z @ inv(cov(z)) @ z.T # por fila
atipico = d2 > chi2.ppf(0.999, 3) # 16.27
```

- **¿Por qué Tukey y no z?** Shapiro–Wilk rechaza normalidad en 10 de 15 casos: $\pm 3\sigma$ supone normalidad; los cuartiles no.
- **¿Por qué $k = 2$?** Más conservador que 1,5: con $n \approx 34$ por vértebra se evita marcar variación anatómica normal.
- **¿Por qué robusta?** Media y desvío se contaminan con los propios atípicos; mediana y MAD no.
- **¿Por qué logaritmo?** Las razones son asimétricas (0,5 y 2 están a la misma distancia de 1).

A3 · Orden craneocaudal y regla de duplicados

```
# duplicados: el mas cercano a la posicion
    esperada
anot["dist"] = (anot.cy_rel
   - anot.vertebra.map(mediana_cy)).abs()
anot = (anot.sort_values("dist")
      .drop_duplicates(["archivo", "vertebra"])
           )

# orden: cy debe crecer de L1 a L5
prev = anot.groupby("archivo").cy_rel.shift(1)
nxt = anot.groupby("archivo").cy_rel.shift(-1)
roto = (prev.notna() & (anot.cy_rel <= prev)) |
     \
      (nxt.notna() & (anot.cy_rel >= nxt))
```

- La posición vertical se normaliza por el alto de la imagen (c_y/alto) para comparar imágenes.
- La mediana por vértebra es el «lugar esperado» de esa vértebra.
- El control de orden compara cada vértebra con sus vecinas en la misma imagen (`shift` dentro del grupo).
- Supuesto: radiografías con la columna vertical (se verificó visualmente).

A4 · Carga del almacén desde la base transaccional

```
ATTACH DATABASE 'spine_oltp.db' AS oltp;
INSERT INTO dim_imagen
SELECT i.imagen_id, i.archivo, i.split, ...,
      COALESCE(i.sexo, 'sin dato'),
      CASE WHEN i.edad < 18 THEN '<18' ... END,
      COUNT(a.vertebra_id),
      CASE WHEN COUNT(a.vertebra_id) = 5
           THEN 1 ELSE 0 END, -- completa
      COALESCE(i.diagnostico_id, 0) -- miembro "
           sin dato"
FROM oltp.imagen i
LEFT JOIN oltp.anotacion a USING (imagen_id)
GROUP BY i.imagen_id;
```

- `LEFT JOIN`: las imágenes sin anotar también entran a la dimensión (P1 las necesita).
- Hechos: métricas recalculadas desde `vertice`, la fuente de verdad.
- `area_norm` y `alto_norm` se calculan con la mediana **por imagen** (`groupby + transform`).
- Validación: conteos por tabla y `PRAGMA foreign_key_check`.

A5 · Momentos y Cobb aproximado

```
cnt = np.column_stack([x, y]).astype(np.float32)
m = cv2.moments(cnt.reshape(-1, 1, 2))
mu20 = m["mu20"] / m["m00"]
mu02 = m["mu02"] / m["m00"]
mu11 = m["mu11"] / m["m00"]
theta = 0.5 * np.degrees(np.arctan2(2*mu11, mu20
    - mu02))
```

```
SELECT imagen_key,
     MAX(inclinacion) - MIN(inclinacion) AS
          cobb_aprox
FROM fact_vertebra_anotada
GROUP BY imagen_key HAVING COUNT(*) >= 4;
```

- Los momentos centrales μ_{pq} son la «covarianza» del contorno: su eje principal es la dirección de máxima dispersión.
- Divididos por m_{00} no dependen del tamaño de la vértebra.
- `atan2` resuelve el cuadrante; el ½ viene de la fórmula del ángulo doble.
- Pruebas no paramétricas porque $n \approx 8$ y no hay normalidad.